

דף היסטוריה על המרד השכיחותני ושובו של בייס: מגוסט ופישר ועד Stan

הקדמה: המרדף אחר אובייקטיביות

בדף הקודם ראינו כיצד תומאס בייס ופייר-סימון לפלס הפכו את כיוון החץ של ברנולי. במקום לשאול "בהינתן הפרמטר, מה הסיכוי לראות את הנתונים?", הם שאלו "בהינתן הנתונים שראינו, מה הסיכוי שהפרמטר הנסתר הוא זה ולא אחר?". כדי לענות על השאלה הזו הם נזקקו להתפלגות מוקדמת (Prior), כלומר לתיאור של מה שחשבנו על הפרמטר לפני שראינו את הנתונים.

הדף הזה מספר מה קרה לרעיון הזה במאה העשרים. הסטטיסטיקה ביקשה להפוך למדע "אובייקטיבי", שבו שני חוקרים שמנתחים את אותם נתונים מגיעים בדיוק לאותה מסקנה. בדרך היא דחקה את בייס הצידה, בנתה גישה חדשה לגמרי, הגישה השכיחותנית (Frequentist), ומאה שנה אחר כך גילתה שהמחסום שהכריע את המלחמה היה בעיקר מחסום חישובי.

חלק א. לפלס, משפט הגבול המרכזי והאירוניה הגדולה

יעקב ברנולי הוכיח בסוף המאה ה-17 את חוק המספרים הגדולים: ככל שנגדיל את המדגם, השכיחות בו תתקרב אל הפרמטר הנסתר. אבל כשניסה לחשב כמה תצפיות צריך, הוא השתמש בחסמים מתמטיים גסים, והגיע למספר המופרז של 25,550 שלפחות מן הכד כדי להגיע ל"ודאות מוסרית".

את החישוב המדויק יותר עשו אחרים. אברהם דה-מואבר הראה כבר ב-1733 שכאשר מספר הניסויים גדול, ההתפלגות הבינומית של ברנולי מתקרבת לעקומת פעמון. לפלס, שעבד על נתוני הלידות העצומים של פריז ולונדון, נתקע מול חסם חישובי קשיח: כדי לחשב את ההתפלגות הפוסטריורית עבור מאות אלפי לידות היה עליו לחשב עצרות של מספרים עצומים במונה ובמכנה. כדי לעקוף את הקיר הזה בלי מחשב, פיתח לפלס קירובים מתמטיים מבריקים, וב-1810 הכליל אותם למה שנקרא היום **משפט הגבול המרכזי** (Central Limit Theorem).

אם חוק המספרים הגדולים של ברנולי אמר לנו *שנגיע ליעד*, משפט הגבול המרכזי אומר לנו איך *"נראה" השגיאות שלנו סביב היעד*. המשפט קובע שהממוצע של מדגם גדול מתפלג בקירוב לפי עקומת פעמון (התפלגות נורמלית) סביב הממוצע האמיתי, כמעט בלי קשר לצורת ההתפלגות של התצפיות הבודדות. אם נדמיין שאנחנו חוזרים על אותו מחקר שוב ושוב, הממוצעים שנקבל יסתדרו בצורת פעמון, ורוחב הפעמון יקטן ככל שהמדגם גדל.

וכאן האירוניה: הכלים האסימפטוטיים של לפלס נולדו כדי לחשב התפלגויות פוסטריוריות בייסיאניות. אבל כבר לפלס עצמו, בשנותיו המאוחרות, שם לב שבמדגמים גדולים אפשר להגיע לאותן תשובות גם בלי לדבר על Prior, רק מתוך הפיזור של הממוצעים. המנוע שנבנה לשרת את בייס הפך במאה העשרים לנשק העיקרי שבעזרתו נדחקה הגישה הבייסיאנית הצידה.

חלק ב. מר גוסט ומבשלת גינס (Student's t)

משפט הגבול המרכזי עובד נהדר כשיש מאות אלפי לידות. אבל מה קורה כשיש לנו חמש תצפיות במעבדה? ויליאם סילי גוסט (William Sealy Gosset) היה כימאי שעבד בתחילת המאה העשרים במבשלת הבירה "גינס" בדבלין. תפקידו היה להשוות זני שעורה, שיטות גידול ותרבויות שמרים, וכל ניסוי כזה היה יקר ולכן קטן. גוסט שם לב

לבעיה: כשמשמשים בעקומת הפעמון במדגם קטן, צריך להציב בה את סטיית התקן כפי שהיא נאמדת מתוך המדגם עצמו, ובמדגם קטן האומדן הזה בעצמו רועש מאוד. התוצאה היא שעקומת הפעמון הרגילה מבטיחה דיוק שאין לנו באמת.

הפתרון של גוסט היה התפלגות חדשה, התפלגות t: עקומת פעמון שטוחה יותר ועם "זנבות" עבים יותר, שמשקפת את חוסר הוודאות הנוסף שבמדגם קטן. ככל שהמדגם גדל, היא מתקרבת לעקומת הפעמון הרגילה. ג'ינס אסרה על עובדיה לפרסם מאמרים, כדי לא לחשוף למתחרים שהיא מעסיקה מדענים, ולכן גוסט פרסם את המאמר ב-1908 תחת שם העט "Student". מכאן השם שאתם תפגשו בכל תוכנה סטטיסטית: Student's t-test. ההישג של "סטודנט" לקח את הסטטיסטיקה התיאורטית אל המעבדה הקטנה, ואל המחקר הפסיכולוגי עם עשרים או שלושים נבדקים.

חלק ג. הדחת בייס והיפוך העולמות

כבר במאה ה-19 החלו פילוסופים ומתמטיקאים (ג'ון ון, ג'ורג' בול ואחרים) לערער על בייס ולפלו. בתחילת המאה העשרים, כשהסטטיסטיקה ביקשה לבסס את עצמה כמדע קשיח, הביקורת הפכה למלחמה גלויה. הנימוק היה פילוסופי: ה-Prior נתפס כסובייקטיבי, אישי ולא מדעי. ולגבי הפתרון של לפלו, "כשאנינו יודעים דבר, ניתן לכל ערך אותה הסתברות", המבקרים הראו שהוא שרירותי: התפלגות "שטוחה" על פרמטר מסוים הופכת ללא-שטוחה ברגע שמנסחים את אותו פרמטר בסקאלה אחרת. אז מהי בעצם "חוסר ידיעה"?

המטרה החדשה הייתה מדע שבו "הנתונים מדברים בעד עצמם". כדי להשיג אותה בוצע היפוך פילוסופי מוחלט:

- **בגישה הבייסיאנית**, הפרמטר הנסתר אינו ידוע לנו, ולכן מותר (ואף צריך) לתאר את הידע שלנו עליו בעזרת התפלגות הסתברות.
- **בגישה השכיחותנית**, הפרמטר הוא עובדה אחת, קבועה ומוחלטת. הוא פשוט הוא. לכן אין לו התפלגות, ואין משמעות לשאלה "מה ההסתברות שהפרמטר הוא 0.5". מה שאקראי הוא רק הנתונים: המדגם שאספנו הוא הגרלה אחת מתוך אינסוף מדגמים שיכולנו לקבל.

המילה "שכיחותני" באה מכאן: הסתברות, בגישה הזו, היא רק שכיחות ארוכת טווח של אירוע שחוזר על עצמו.

חלק ד. רונלד פישר: חקלאות, אגו סוער ו-MLE

הדמות המרכזית במהפכה הזו הייתה רונלד פישר (Ronald A. Fisher), גנטיקאי וגאון מתמטי שהניח חלק גדול מיסודות הסטטיסטיקה המודרנית בשנים שבהן עבד בתחנת המחקר החקלאית רותמסטד באנגליה (1919 עד 1933). ניסויי הדשן והזרעים בשדות של רותמסטד הולידו את תכנון הניסויים, את ההקצאה האקראית (randomization) ואת ניתוח השונות (ANOVA). פישר נודע גם כאדם עוקצני ועקשן, שניהל מלחמות אגו מרות עם רבים מעמיתיו, ובראשם קרל פירסון, הסטטיסטיקאי הבכיר של הדור הקודם.



רונלד פישר: שחזור של דמותו

כדי להיפטר מה-Prior, פישר פיתח (בין 1912 ל-1922) את **אומד הנראות המרבית** (Maximum Likelihood Estimate, MLE): ערך הפרמטר שתחתיו הנתונים שראינו הם הכי סבירים. זו בדיוק פונקציית ה-Likelihood שאתם כבר מכירים מהשבועות הקודמים, אבל עם שינוי חשוב בפרשנות. פישר התעקש שהנראות אינה התפלגות הסתברות על הפרמטר: לא מחשבים שטח מתחתיה ולא מנרמלים אותה. היא כלי שמחפשים בו את פסגת ההר, ומודדים כמה חדה הפסגה.

פישר גם הפך את **ערך ה-p** (p-value) לכלי עבודה יומיומי. הרעיון עצמו קדום יותר (קרל פירסון חישב ערכים כאלה כבר ב-1900), אבל ספרו של פישר מ-1925, *Statistical Methods for Research Workers*, הפך אותו לשגרה, והציע את

0.05 כנקודת ייחוס נוחה. אצל פישר ערך ה-p היה מדד רציף לעד כמה התוצאה מפתיעה בהנחה שהשערת האפס נכונה, ראייה אחת שהחוקר שוקל, ולא כלל החלטה אוטומטית.

חלק ה. מודדים ודאות בלי הסתברות: התפלגות הדגימה

אם אסור לדבר על "ההסתברות של הפרמטר", איך חוקר יכול לומר עד כמה הוא בטוח באומדן שלו? הפתרון השכיחותני הוא ניסוי מחשבה: **שכיחות ארוכת טווח** (Long-run frequency). מדמיינים שהניסוי שלנו חוזר על עצמו אינסוף פעמים באותם תנאים בדיוק. בכל חזרה מקבלים מדגם חדש וממוצע חדש. אוסף כל הממוצעים ההיפותטיים האלה הוא **התפלגות הדגימה** (Sampling Distribution), ובעזרת משפט הגבול המרכזי והתפלגות t אפשר לדעת את צורתה בלי לבצע אף חזרה בפועל.

על הבסיס הזה בנה יז'י ניימן ב-1937 את **רווח הסמך** (Confidence Interval). רווח סמך של 95% אינו אומר שיש 95% סיכוי שהפרמטר נמצא ברווח הספציפי שחישבנו; הפרמטר קבוע, והוא או שם או לא. המספר 95% מתאר את השיטה: אם נחזור על הניסוי אינסוף פעמים ונחשב בכל פעם רווח באותה דרך, 95% מהרווחים ילכדו את הפרמטר.

זה פתרון מבריק, אבל יש לו מחיר. השיטה הנפוצה נשענת כולה על נקודת ה-MLE ועל קירוב של עקומת פעמון סביבה, ובמדגמים קטנים היא עלולה לקרוס. דוגמה קלאסית: 10 הצלחות מתוך 10 ניסיונות. ה-MLE הוא 1, ושגיאת התקן המשוערת, $\sqrt{\hat{p}(1-\hat{p})/n}$, יוצאת אפס. רווח הסמך הוא הנקודה 1 בלבד, כאילו אנחנו בטוחים לחלוטין שהצלחה מובטחת תמיד. הגישה הבייסיאנית, שמחזיקה התפלגות שלמה על הפרמטר, לא נופלת בפח הזה.

חלק ו. ניימן, פירסון ובקרת האיכות של המדע

בשנות השלושים הגיעו לזירה יז'י ניימן (Jerzy Neyman), מתמטיקאי פולני, ואגון פירסון (Egon Pearson), בנו של קרל פירסון, עם תפיסה שונה לחלוטין. פישר שאל מה **המדגם הזה** מלמד אותנו. ניימן ופירסון שאלו שאלה אחרת: איזה כלל **החלטה** יגרום לנו לטעות כמה שפחות לאורך זמן? ניימן קרא לזה "התנהגות אינדוקטיבית" (inductive behavior), בניגוד ל"היסק אינדוקטיבי" של פישר. המערכת שלהם (1933) מזכירה בקרת איכות בפס ייצור יותר מאשר חקירה מדעית פתוחה, והיא הורישה לנו את הכללים המוכרים:

- השערת אפס מול **השערה חלופית** מוגדרת היטב;
- **טעות מסוג I** (α , לדחות השערת אפס נכונה) ו**טעות מסוג II** (β , לא לדחות השערת אפס שגויה);
- **עוצמה סטטיסטית** (Power, $1 - \beta$), שמחשבים לפני הניסוי כדי לקבוע את גודל המדגם;
- סף α שנקבע מראש, ואחריו החלטה בינארית: דוחים או לא דוחים. אצל ניימן ופירסון אין משמעות ל"כמעט מובהק".

חלק ז. מלחמת האגו והמוטציה שנקראת NHST

ההבדל בין הגישות הוליד את אחד הריבים הארוכים במדע של המאה העשרים. פישר טען שניימן ופירסון הופכים את המדען לפקיד שמבצע עבודה מכנית בלי שיקול דעת, והשווה את שיטתם לבקרת איכות במפעלים ולתוכניות החומש הסובייטיות. ניימן מצידו טען שמבחן בלי השערה חלופית ובלי שליטה בשיעור הטעויות לאורך זמן אינו מבחן של ממש. השניים לא השלימו עד מותו של פישר ב-1962.

הטרגדיה, והסיבה שסטודנטים מתקשים במושגים האלה עד היום, היא שמחברי ספרי הלימוד בשנות הארבעים והחמישים, בעיקר בפסיכולוגיה ובמדעי החברה, לא הכריעו בין הגישות. הם תפרו אותן יחד לכלאיים אחד שאף אחד מהממציאים לא היה מסכים לו: **בדיקת השערות מובהקות** (Null Hypothesis Significance Testing, NHST). ממנו קיבלנו את ההרגל לדווח ערך p מדויק (פישר) לצד סף 0.05 קבוע ודחייה בינארית (ניימן ופירסון), בלי השערה

חלופית מוגדרת ובלי חישוב עוצמה. הפסיכולוג גרד גיגרנצר כינה את התוצאה "ריטואל סטטיסטי", ונחזור אליו בהמשך הקורס, כשנדבר על משבר הרפליקציה.

חלק ח. השיבה: מחשבים, Stan ו-MCMC

אם הגישה הבייסיאנית כל כך הגיונית, מדוע הגישה השכיחותנית שלטה כמעט מאה שנה? מלבד הוויכוח הפילוסופי, הייתה סיבה מעשית מאוד. עבור פישר, מציאת פסגת ה-MLE הייתה בדרך כלל פעולה אלגברית קצרה: גוזרים ומשווים לאפס. לעומת זאת, כדי לקבל פוסטריור בייסיאני מלא במודל עם כמה פרמטרים, צריך לפתור את האינטגרל שבמכנה של נוסחת בייס, ובמודלים מורכבים אי אפשר לפתור אותו בעיפרון ונייר.

הפתרון הגיע ממקום לא צפוי. ב-1953, במעבדת לוס אלמוס, פיתחו ניקולס מטרופוליס וחבריו שיטה לדגימה אקראית מהתפלגויות מסובכות לצורך חישובים בפיזיקה. רק ב-1990 הראו אלן גלפנד ואדריאן סמית' לסטטיסטיקאים שאותה משפחת שיטות, **MCMC** (Markov Chain Monte Carlo), פותרת בדיוק את הבעיה של בייס. במקום לפתור את האינטגרל, האלגוריתם "מטייל" במרחב הערכים האפשריים של הפרמטר: הוא שווה יותר זמן באזורים שבהם הפוסטריור גבוה (כלומר, שבהם Prior כפול Likelihood גבוה) ופחות זמן באזורים שבהם הוא נמוך. אחרי מספיק צעדים, ההיסטוגרמה של המקומות שבהם ביקר היא ציור של הפוסטריור כולו.

תוכנות כמו BUGS (משנות התשעים) ו-Stan (מ-2012, ונקראת על שם סטניסלב אולם, ממציא שיטת מונטה קרלו) הפכו את הכלי הזה לנגיש לכל חוקר. הטכנולוגיה שחררה את בייס מהכלא החישובי, ואפשרה לסטטיסטיקה לחזור לשאלה ההפוכה שהטרידה את ברנולי מלכתחילה: בהינתן התצפיות שראינו, מה ההסתברות לכל אחד מהערכים האפשריים של הפרמטר הנסתר? בקורס הזה נשתמש בשתי הגישות זו לצד זו, ונראה מתי הן מסכימות ומתי לא.

סיכום: מה חייב להיות ידוע לכם כשתיכנסו לכיתה

אלה השאלות שעליהן אתם צריכים להיות מסוגלים לענות אחרי קריאת הדף (הן לא להגשה, אלא כמכוון עבורכם):

1. מה ההבדל בין מה שחוק המספרים הגדולים מבטיח לבין מה שמשפט הגבול המרכזי מוסיף?
2. מהי האירוניה ההיסטורית בסיפור של משפט הגבול המרכזי?
3. איזו בעיה פתר ויליאם גוסט בהתפלגות t , ומדוע פרסם אותה תחת השם "Student"?
4. מה ההבדל בין מעמדו של הפרמטר בגישה הבייסיאנית לבין מעמדו בגישה השכיחותנית?
5. מהו אומד הנראות המרבית (MLE), ומה ההבדל בין האופן שבו פישר פירש את פונקציית ה-Likelihood לבין האופן שבו היא משמשת בנוסחת בייס?
6. מהי התפלגות דגימה, ומה בדיוק אומר (ומה לא אומר) רווח סמך של 95%?
7. מה ההבדל בין הגישה של פישר לגישה של ניימן ופירסון, ומה זה NHST?
8. מדוע הגישה הבייסיאנית חזרה לשימוש רחב רק בסוף המאה העשרים?

שאלות לדיון בכיתה

1. חוקרת בודקת טיפול חדש על 10 מטופלים, וכל ה-10 משתפרים. מה תאמר הגישה השכיחותנית (עם MLE ושגיאת תקן) על הסיכוי שהמטופל הבא ישתפר? מה הייתם רוצים לומר לה בפועל, ומה זה מלמד על ההבדל בין הגישות?
2. האידיאל השכיחותני הוא ששני חוקרים עם אותם נתונים יגיעו לאותה מסקנה. האם האידיאל הזה אפשרי באמת? חשבו על כל ההחלטות שחוקר מקבל לפני שהוא מחשב ערך p (מה למדוד, את מי לדגום, מתי להפסיק לאסוף נתונים).

3. פישר האשים את ניימן בכך שהוא הופך את המדען לפקיד. ניימן האשים את פישר בכך שאין לו שליטה בשיעור הטעויות. אם הייתם עורכי כתב עת בפסיכולוגיה, איזו גישה הייתם דורשים מהמחברים, ולמה?