אוניברסיטת תל אביב
בעקבות הלא נודע

שתי דרכים, פרמטר אחד

הערכה Bayesian והערכה Frequentist של פרמטר ברנולי חבוי

פרופ׳ ניצן שחר

שתי דרכים להסקה לאחור

Bayesian

איך מסיקים: מחלקים אמינות בין כל ערכי הפרמטר, ומעדכנים אותה לפי הנתונים. התוצאה: התפלגות, ה-**posterior**.

מה דורשת: **prior**: כמה כל ערך אמין עוד לפני הנתונים.

מהי אי-ודאות: הבורות שלנו. הפרמטר ודאי, והידע שלנו עליו חלקי.

חישוב: כבד. במודלים אמיתיים, רק במחשב.

Frequentist

איך מסיקים: מניחים ערך יחיד לפרמטר, ושואלים כמה צפויים נתונים כמו שלנו, או קיצוניים יותר. התוצאה: אומדן ($\hat{\theta}$) וערך p.

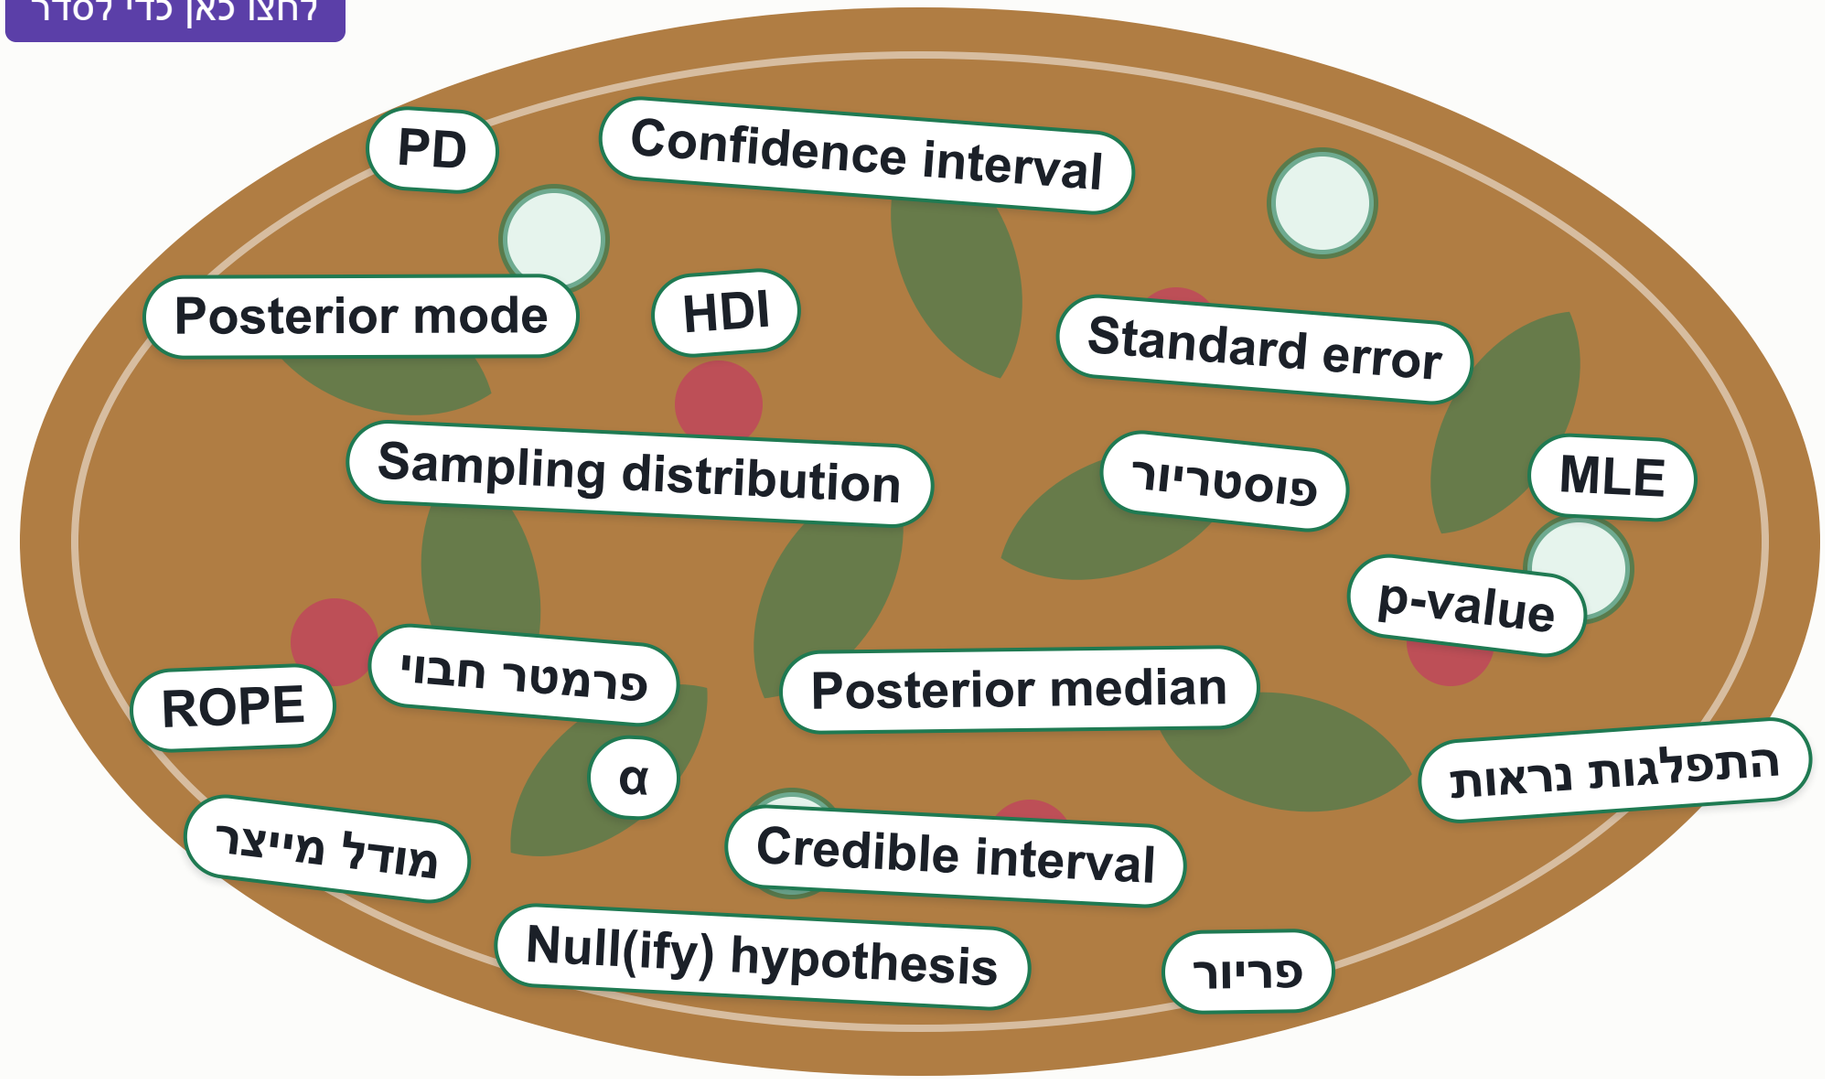
מה דורשת: השערה ברת-הפרכה: ערך אחד (לרוב "אין אפקט") שמנסים להפריך. בלי **prior**.

מהי אי-ודאות: הרעש בנתונים. הפרמטר קבוע, וכל מדגם יוצא קצת אחרת.

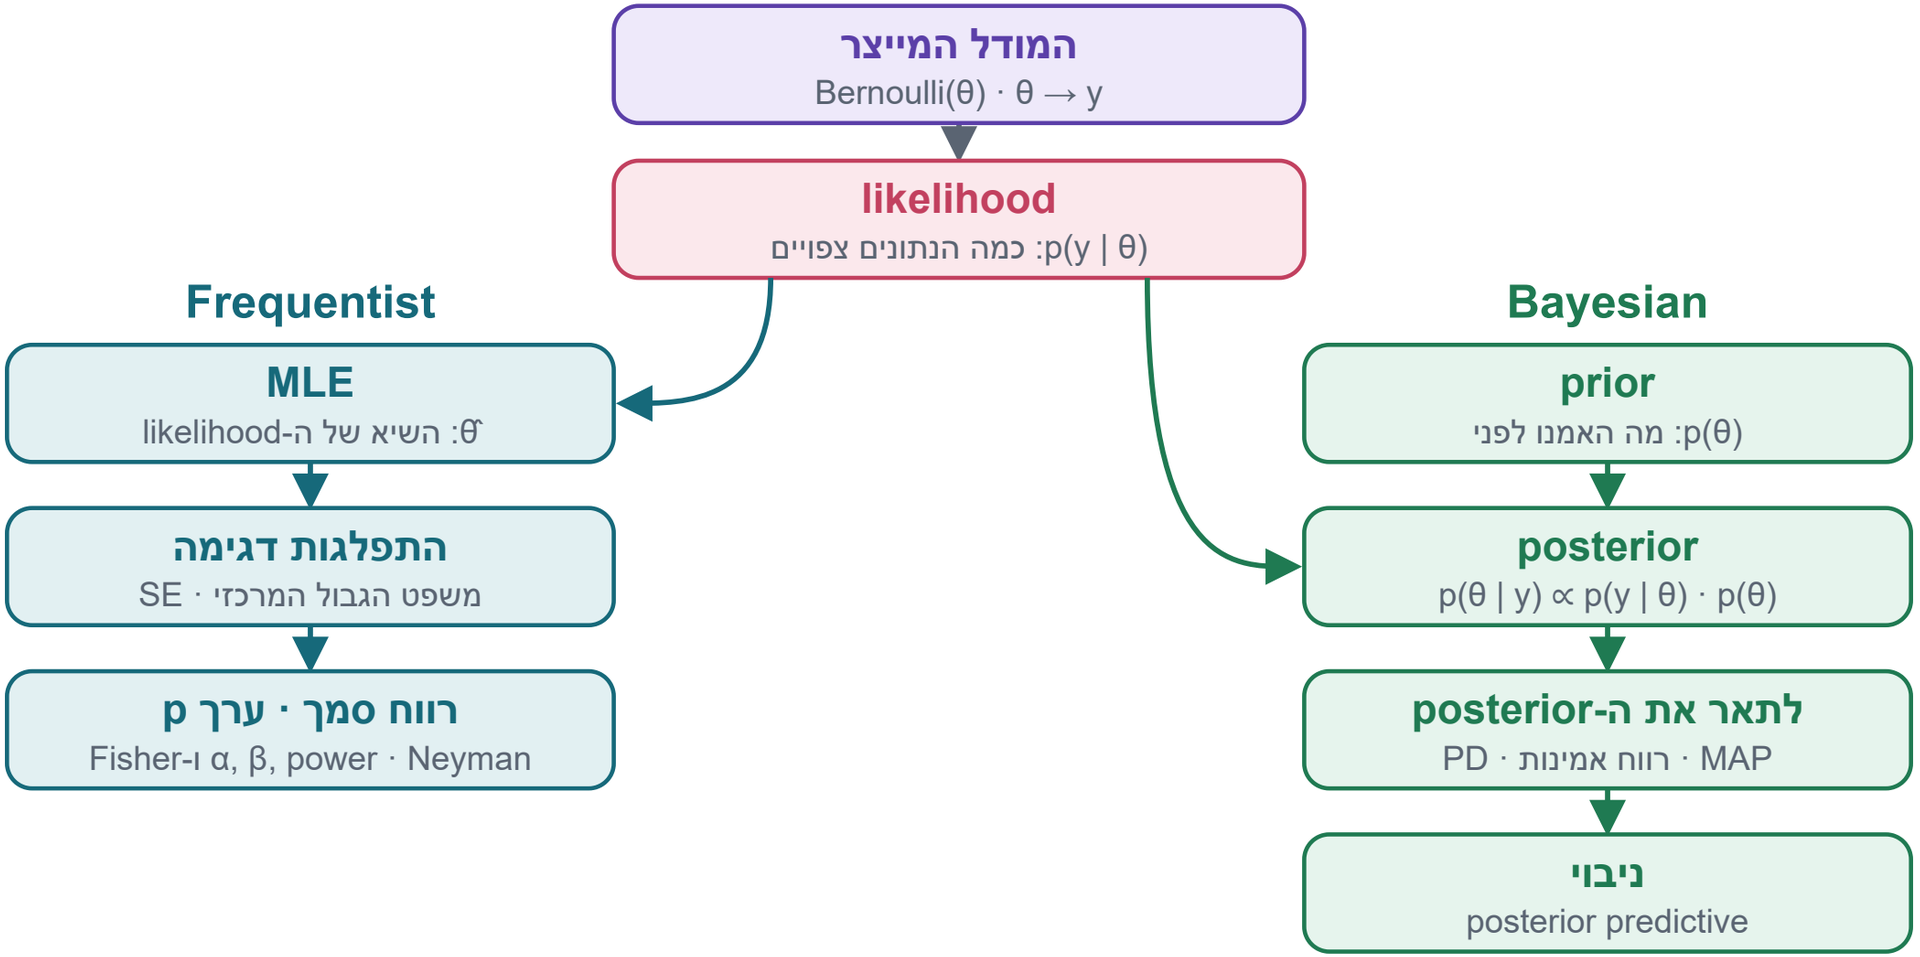
חישוב: קל. נוסחה סגורה, ביד או במחשבון.

סלט בראש?

לחצו כאן כדי לסדר

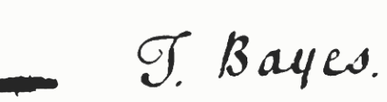


המפה

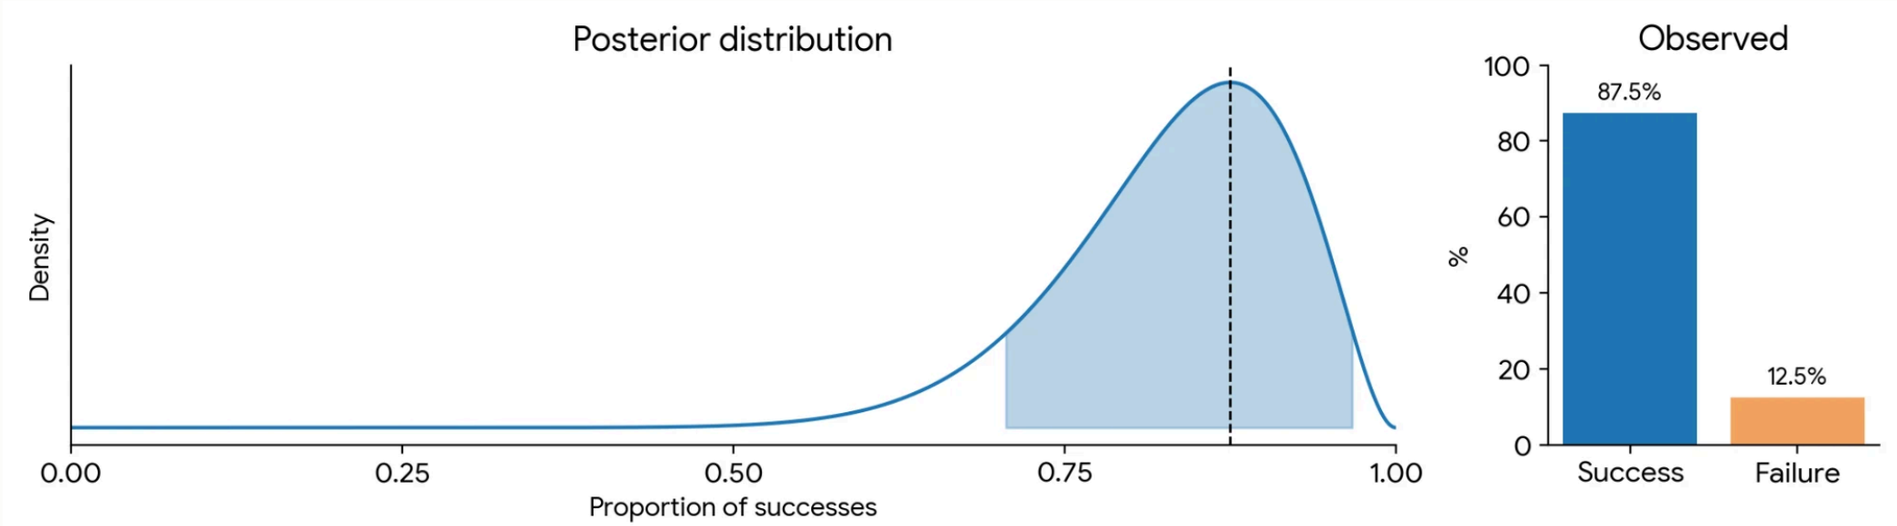


לחצו על תיבה כדי לראות מה היא אומרת.





Bayesian דיווח

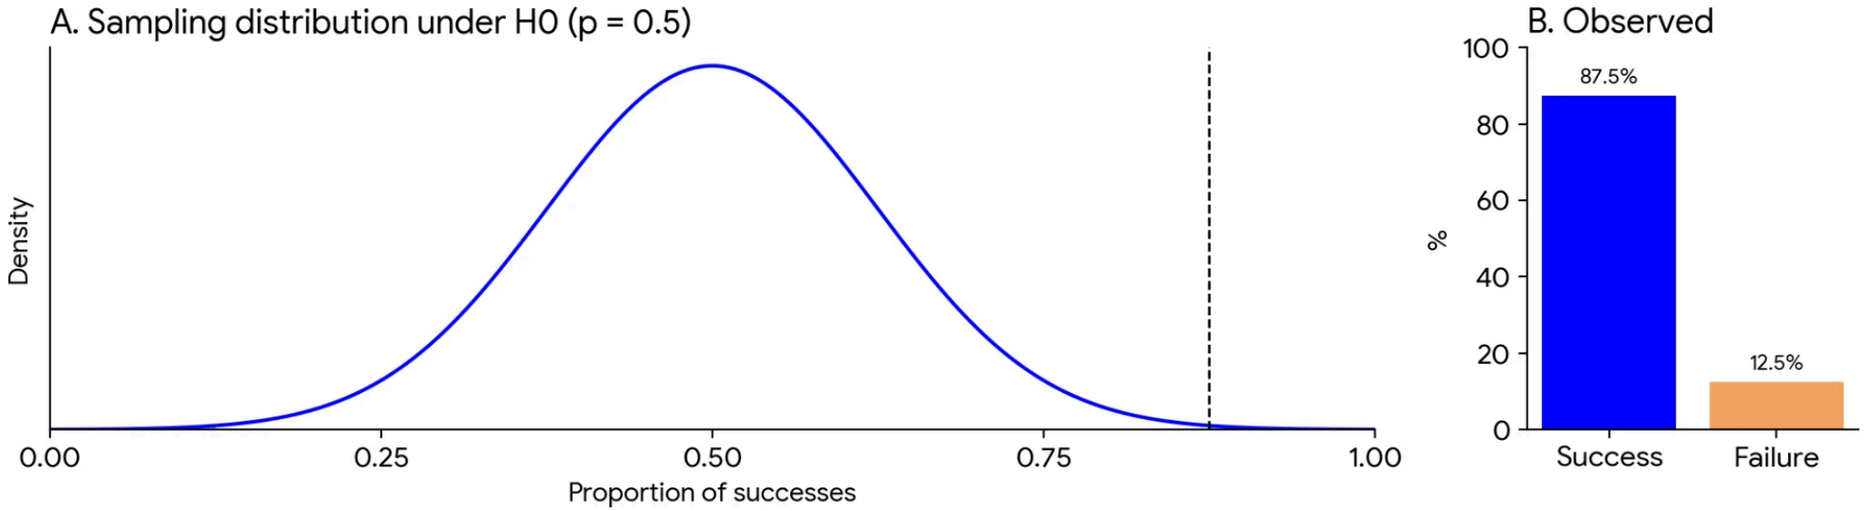



```
Success: 14 | Failure: 2 | n = 16
Mode: 0.875
90% HDI: [0.705, 0.968]
Probability of direction (vs. 0.5): 99.9% (favors p > 0.5)
ROPE [0, 0.10]: 0.0% of posterior mass inside
```

לדיון: לשאלה על התינוקות, איזה ROPE היה מתאים יותר? איפה יושב "אין העדפה, מעשית"?

R. A. Fisher

Frequentist דיווח




```
Successes: 14 | Failures: 2 | n = 16
MLE (p-hat): 0.875
90% Confidence Interval: [0.656, 0.977]
Two-sided p-value (vs. H0: p = 0.5): 0.004
One-sided p-value: 0.002 (in direction of p > 0.5)
```

המסקנה: p קטן מ-0.05, ולכן דוחים את H_0: לתינוקות יש העדפה. זה משפט על הנתונים בהינתן H_0, ולא הסיכוי ש-H_0 נכונה.

הערכה Bayesian של פרמטר ברנולי

מהמודל המייצר, דרך likelihood ו-prior, אל ה-posterior.

מהנתונים אל ה-posterior



θ = ■

θ חבוי: הטבע יודע אותו, ואנחנו לא. רואים רק את מה שהוא מייצר.

הערכה Frequentist של פרמטר ברנולי

אותה likelihood, ומשם MLE, ההשערה ברת-ההפרכה וערך p.

מהנתונים אל ערך p

θ = ■

אותו θ חבוי, אותם נתונים.
הפעם בלי prior.