אוניברסיטת תל אביב
בעקבות הלא נודע

הערכה Frequentist ב-Bernoulli

MLE, משפט הגבול המרכזי, בדיקת השערות ו-Student

פרופ׳ ניצן שחר

מהעיקרון למספרים

- במצגת הקודמת: θ קבוע, הנתונים אקראיים. MLE, התפלגות דגימה, ערך p, α ו-**power**.
- עכשיו הכול במספרים, ועל מודל אחד: $y_i \sim \text{Bernoulli}(\theta)$.
- בסוף המצגת תדעו כל מה שצריך כדי לקרוא ניתוח **frequentist** של פרמטר אחד: אומדן, טעות תקן, רווח סמך, ערך p ו-**power**.

ה-MLE של Bernoulli

k הצלחות מתוך n. ה-**likelihood** מהשבוע הראשון:

$$\mathcal{L}(\theta) = \theta^k (1-\theta)^{n-k}$$

קל יותר למצוא את השיא של הלוגריתם (אותו שיא, כי $\log$ עולה):

$$\log \mathcal{L}(\theta) = k \log \theta + (n-k) \log(1-\theta)$$

גוזרים ומשווים לאפס:

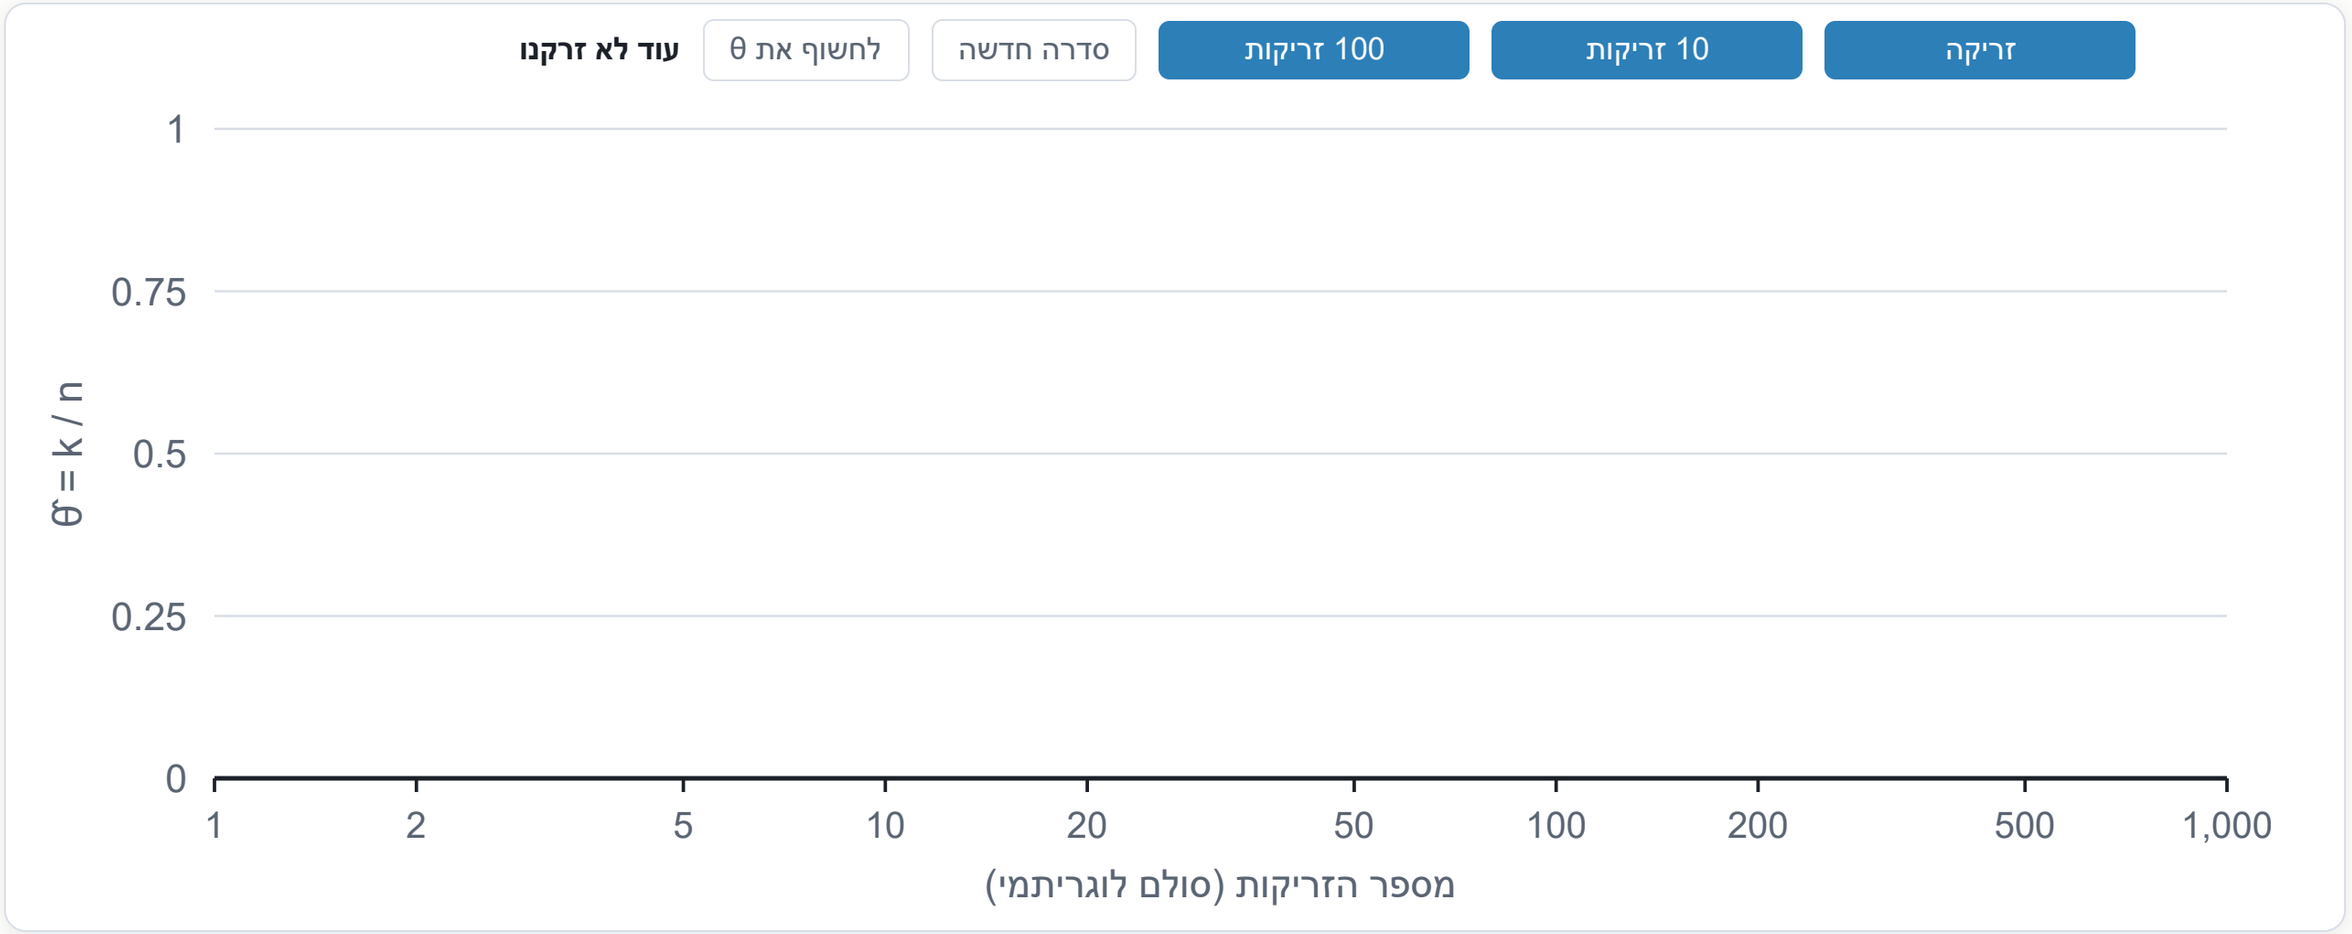
$$\frac{k}{\theta} - \frac{n-k}{1-\theta} = 0 \quad \Longrightarrow \quad \hat{\theta} = \frac{k}{n}$$

שלוש שורות של אלגברה, בלי אינטגרל. **ה-MLE של Bernoulli הוא פשוט שיעור ההצלחות.**

דוגמה: הגלובוס

- הזריקות של McElreath: ים, יבשה, ים, ים, ים, יבשה, ים, יבשה, ים. 6 ים מתוך 9.
- $\hat{\theta} = 6/9 = 0.67$.
- בשבוע שעבר, עם **prior** אחיד, ה-MAP של ה-**posterior** יצא **בדיוק אותו מספר**.
- אבל שם היה לנו גם את כל העקומה. כאן יש לנו **מספר אחד**. ומה הלאה?

ה-MLE זריקה אחר זריקה



כל זריקה מוסיפה תצפית, ומעדכנת את $\hat{\theta}$. "סדרה חדשה" משאירה את הסדרות הקודמות באפור.

מה הגרף מראה

- **ה-MLE מתכנס ל-θ.** זה חוק המספרים הגדולים של Bernoulli. לאומדן שמתכנס קוראים **consistent**.
- **בהתחלה הוא קופץ.** אחרי 5 זריקות $\hat{\theta}$ יכול להיות כמעט כל דבר.
- **כל סדרה נראית אחרת.** באותו n, סדרות שונות נותנות $\hat{\theta}$ שונים.
- אבל בגרף שיש לכם ביד יש **סדרה אחת**, ו-θ מוסתר. המספר $\hat{\theta}$ לבדו לא אומר כמה הוא רחוק מ-θ.

אז מה אפשר לעשות?

שתי תשובות

Bayesian · שבוע שעבר

שמים התפלגות על θ. ה-**posterior** רחב כשיש מעט נתונים וצר כשיש הרבה. הרוחב הוא אי-הוודאות.

Frequentist · היום

θ קבוע, ולכן שואלים על **השיטה**: אם היינו חוזרים על הניסוי עם אותו n, עד כמה $\hat{\theta}$ היה מתפזר? זו ה-**sampling distribution**. ואת הצורה שלה נותן Laplace.

משפט הגבול המרכזי: ההגדרה

יהיו $y_1, \ldots, y_n$ תצפיות בלתי תלויות מ-$\text{Bernoulli}(\theta)$, עם $0 < \theta < 1$, ויהי $\hat{\theta}_n = \frac{1}{n}\sum_{i=1}^{n} y_i$. אז לכל $a < b$:

$$\lim_{n\to\infty} P\left(a \;\le\; \frac{\hat{\theta}_n - \theta}{\sqrt{\theta(1-\theta)/n}} \;\le\; b \right) = \int_a^b \frac{1}{\sqrt{2\pi}}\, e^{-z^2/2}\, dz$$

- בכתיב מקוצר: $\hat{\theta} \;\dot\sim\; \mathcal{N}\left(\theta,\ \frac{\theta(1-\theta)}{n}\right)$. מרכז θ, סטיית תקן $\sqrt{\theta(1-\theta)/n}$.
- זה משפט de Moivre–Laplace: de Moivre הוכיח אותו ל-$\theta = \frac{1}{2}$ ב-1733, ו-Laplace לכל θ.
- הגרסה הכללית: לכל תצפיות בלתי תלויות מאותה התפלגות, עם ממוצע μ ושונות סופית σ^2, $\frac{\bar{y} - \mu}{\sigma/\sqrt{n}}$ מתקרב לאותו פעמון.

Laplace, במילים שלו

anomalies due to hazard. The theory of discriminant functions gives a very simple expression for this probability, which is obtained by integrating the product of the differential of the quantity of which the result deduced from a great number of observations varies from the truth by a constant less than unity, dependent upon the nature of the problem, and raised to a power whose exponent is the ratio of the square of this variation to the number of observations. The integral taken between the limits given and divided by the same integral, applied to a positive and negative infinity, will express the probability that the variation from the truth is comprised between these limits. Such is the general law of the probability of results indicated by a great number of observations.

Laplace, *A Philosophical Essay on Probabilities*, 1814, עמ' 72

> [...] ביטוי פשוט מאוד להסתברות הזו: מקבלים אותו מאינטגרל של מכפלה. הסטייה של התוצאה, שהוסקה ממספר גדול של תצפיות, מן האמת, כפול קבוע קטן מאחד, **המועלה בחזקה שהמעריך שלה הוא ריבוע הסטייה חלקי מספר התצפיות**. האינטגרל בין הגבולות הנתונים, מחולק באותו אינטגרל ממינוס אינסוף עד פלוס אינסוף, יבטא את ההסתברות שהסטייה מן האמת נמצאת בין הגבולות האלה. **זהו החוק הכללי של ההסתברות של תוצאות שמתקבלות ממספר גדול של תצפיות.**

$$P(l_1 \le x \le l_2) = \frac{\int_{l_1}^{l_2} c^{\,x^2/n}\,dx}{\int_{-\infty}^{\infty} c^{\,x^2/n}\,dx}, \qquad c = e^{-1/(2\theta(1-\theta))}, \quad x = k - n\theta$$

עם הקבוע הזה, $c^{x^2/n} = e^{-(k-n\theta)^2/(2n\theta(1-\theta))}$: פעמון. מחלקים ב-$n$, ומקבלים את ההגדרה מהשקף הקודם.

אלף ניסויים דמיוניים



כל ניסוי: n זריקות, ומחשבים $\hat{\theta}$. העמודות הן ההיסטוגרמה של כל ה-$\hat{\theta}$, והקו הסגול הוא θ. נסו $n = 1$, אחר כך $n = 5$ עם $\theta = 0.1$, ואז $n = 500$.

מה הפעמון נותן

- **מרכז:** הממוצע של $\hat{\theta}$ על פני ניסויים הוא θ. לאומדן כזה קוראים **unbiased**.
- **רוחב:** סטיית התקן של התפלגות הדגימה נקראת **standard error** (SE):

$$SE(\hat{\theta}) = \sqrt{\frac{\theta(1-\theta)}{n}}$$

- פי ארבעה זריקות, חצי SE. זו הסיבה שמחקרים גדולים יקרים כל כך.
- **צורה:** הפעמון טוב כשיש מספיק הצלחות **וגם** מספיק כישלונות. כלל אצבע: לפחות 10 מכל סוג. עם $n = 5$ ו-$\theta = 0.1$ ראיתם מה קורה בלי זה.

טעות תקן ורווח סמך

- **המלכוד:** ב-SE מופיע θ, ואותו אנחנו לא יודעים. הפתרון המעשי: להציב במקומו את $\hat{\theta}$.

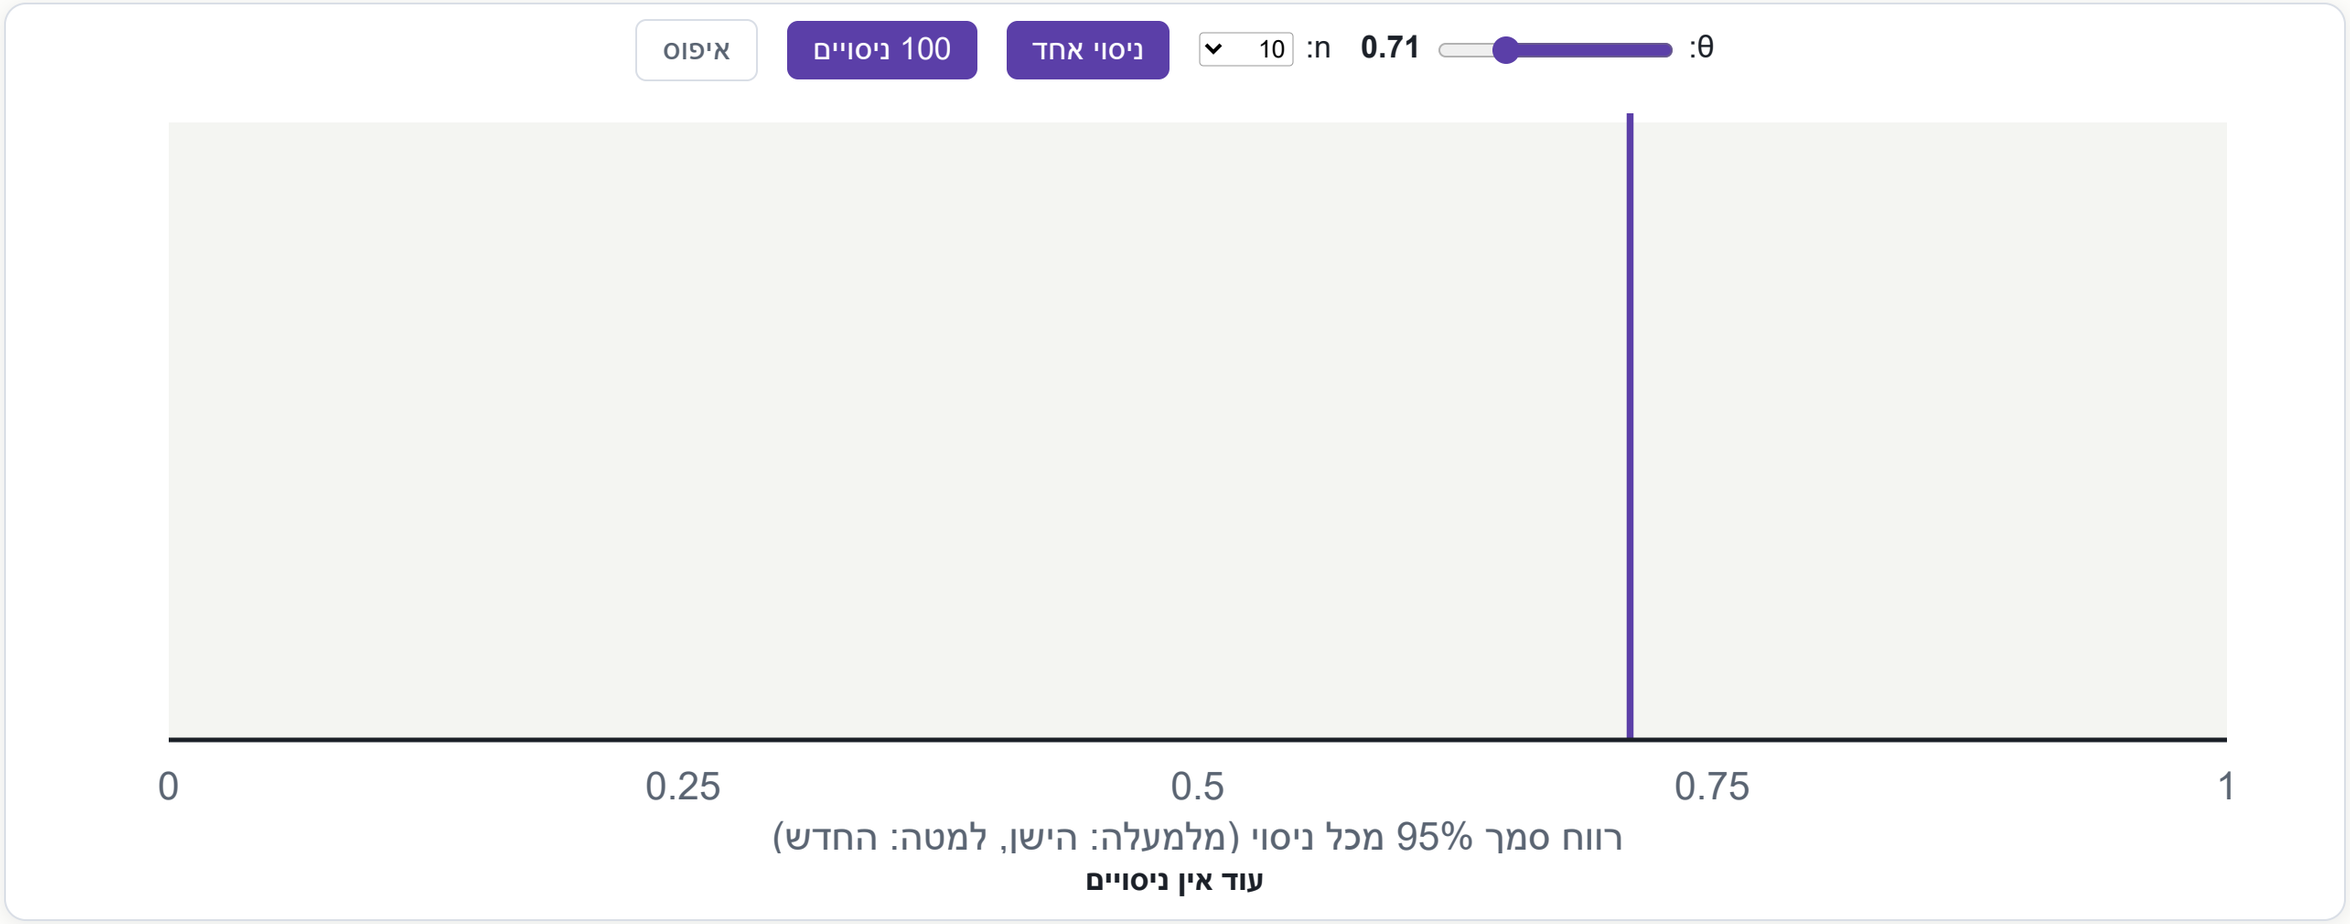
$$\widehat{SE} = \sqrt{\frac{\hat{\theta}(1-\hat{\theta})}{n}}$$

- בפעמון, 95% מהמסה נמצאים בטווח ± 1.96 סטיות תקן ("1.96, או כמעט 2" של Fisher). מכאן **Wald interval**:

$$\hat{\theta} \pm 1.96 \cdot \widehat{SE}$$

- הגלובוס, 6 מתוך 9: $\widehat{SE} = \sqrt{0.67 \cdot 0.33/9} = 0.157$, ורווח הסמך הוא 0.67 ± 0.31, כלומר $[0.36,\ 0.97]$.

מאה ניסויים, מאה רווחים



כל שורה היא ניסוי אחד והרווח שחושב ממנו. אדום: רווח שפספס את θ. נקודה אדומה: רווח באורך אפס. נסו $n = 10$ עם $\theta = 0.9$, ואז $n = 1000$.

כשהקירוב נשבר: 10 מתוך 10

- טיפול חדש ניתן ל-10 מטופלים, וכולם השתפרו.
- $\hat{\theta} = 1$, $\widehat{SE} = \sqrt{1 \cdot 0/10} = 0$, ורווח הסמך הוא $[1,\ 1]$: "בטוחים לחלוטין שהטיפול עובד תמיד".
- שתי הנחות נשברו יחד: n קטן מדי לפעמון, וה-$\hat{\theta}$ שהוצב ב-SE רחוק מ-θ.
- ה-95% הוא הבטחה **לאורך זמן ובקירוב**. ב-n קטן, או כש-θ קרוב ל-0 או ל-1, רווח Wald מכסה הרבה פחות. ראיתם את זה בהדגמה.
- יש רווחים **frequentist** שעובדים גם כאן (Wilson 1927, Clopper ו-Pearson 1934).
  וה-**posterior** עם **prior** אחיד לא קורס: נראה את זה במצגת הבאה.

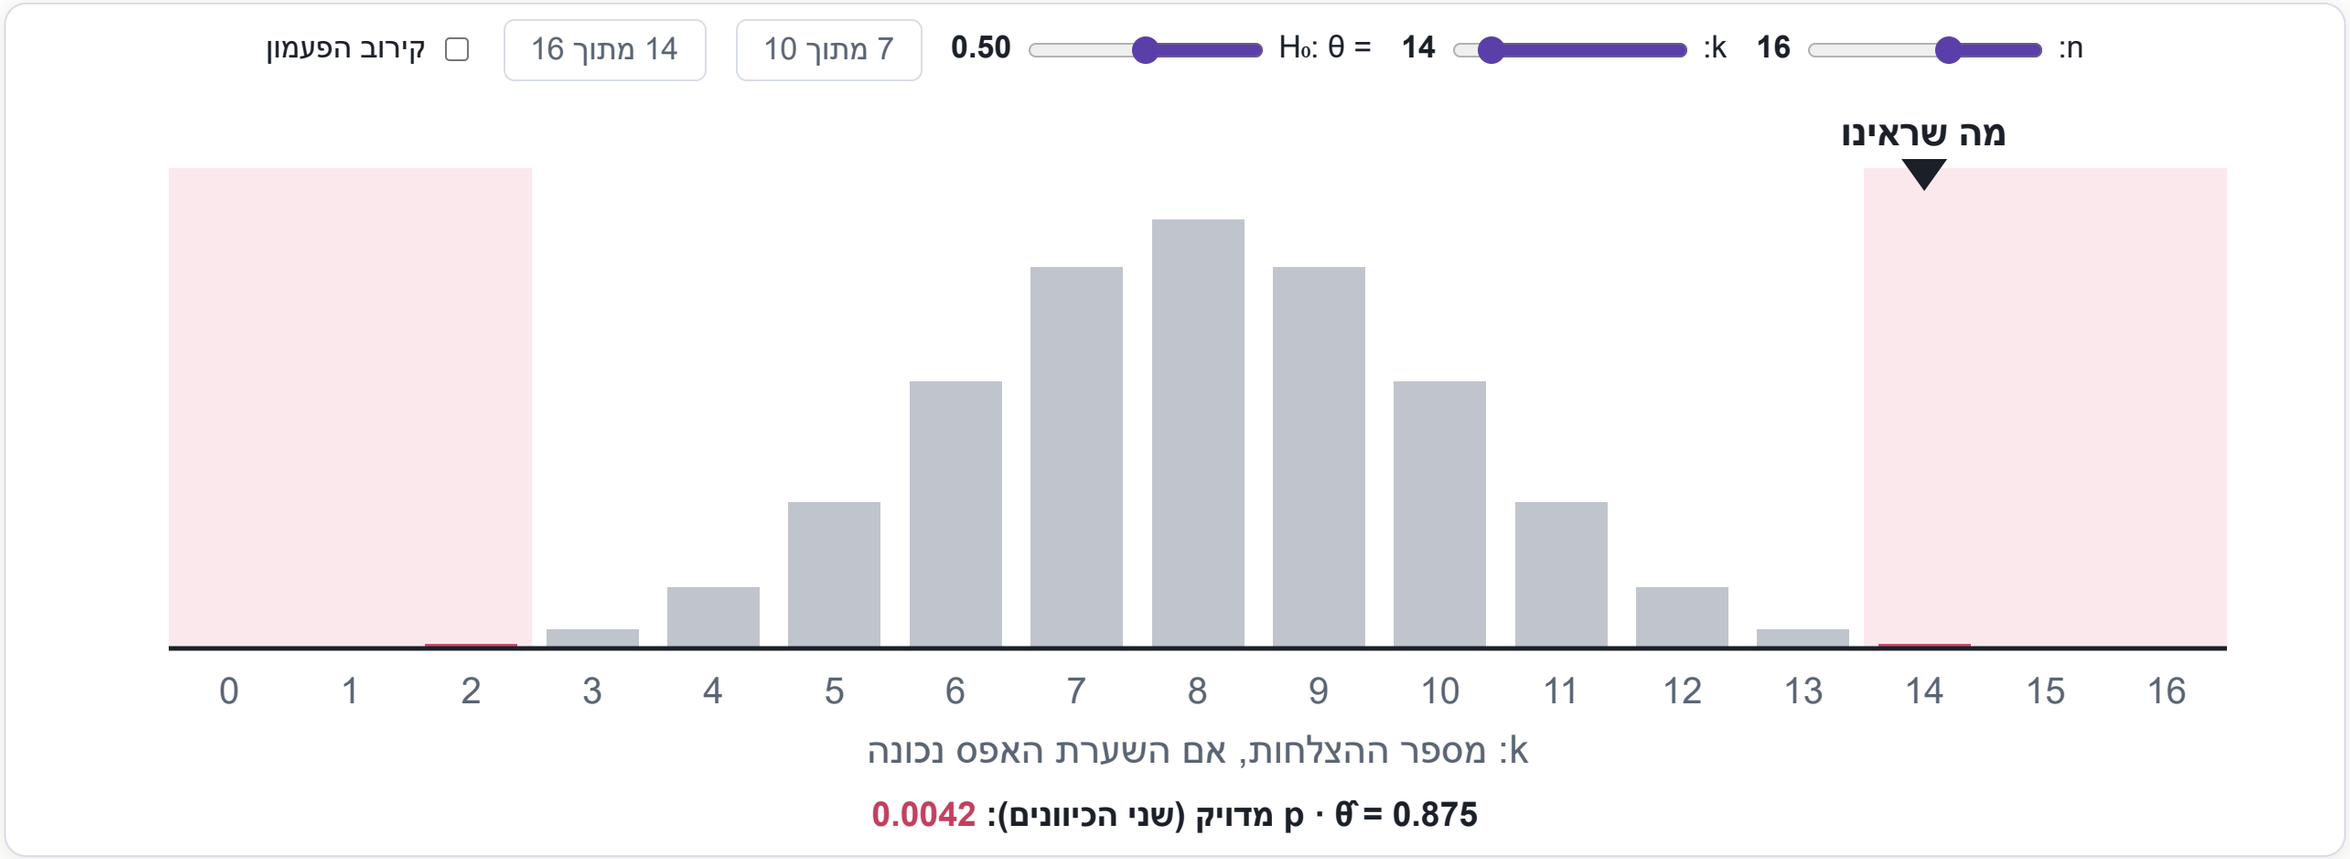
בדיקת השערות: התינוקות

- Hamlin, Wynn ו-Bloom (2007): תינוקות בני 10 חודשים צפו בדמות "עוזרת" ובדמות "מפריעה", ואחר כך בחרו באחת.
- **14 מתוך 16** בחרו בעוזרת. $\hat{\theta} = 0.875$.
- **השערת האפס**: לתינוקות אין העדפה. $H_0 : \theta = 0.5$.
- השאלה של Fisher: **אם** H_0 נכונה, עד כמה 14 מתוך 16 מפתיע?

ערך ה-p, צעד אחר צעד

1. **התפלגות הדגימה תחת H_0:** אם $\theta = 0.5$, אז לפי הפעמון $\hat{\theta} \sim \mathcal{N}(0.5,\ 0.125^2)$, כי $\sqrt{0.5 \cdot 0.5/16} = 0.125$.
2. **כמה רחוק מה שראינו**, ביחידות SE (**z**): $z = \dfrac{0.875 - 0.5}{0.125} = 3$.
3. **ערך p:** ההסתברות להיות רחוק לפחות כך, לכל כיוון. $p = P(|Z| \geq 3) = 0.0027$.
4. **בלי פעמון:** אפשר לספור ישירות בהתפלגות הבינומית של k. $p = 0.0042$.
5. 0.0042 קטן מ-0.05: התוצאה **מובהקת**.

ערך ה-p בהדגמה



העמודות: ההסתברות לכל k **אם** H_0 נכונה. באדום: כל התוצאות שרחוקות מ-H_0 לפחות כמו מה שראינו. ערך ה-p הוא הסכום שלהן. 7 מתוך 10 (המופע מהשבוע שעבר) הוא 70%, ועדיין לא מובהק.

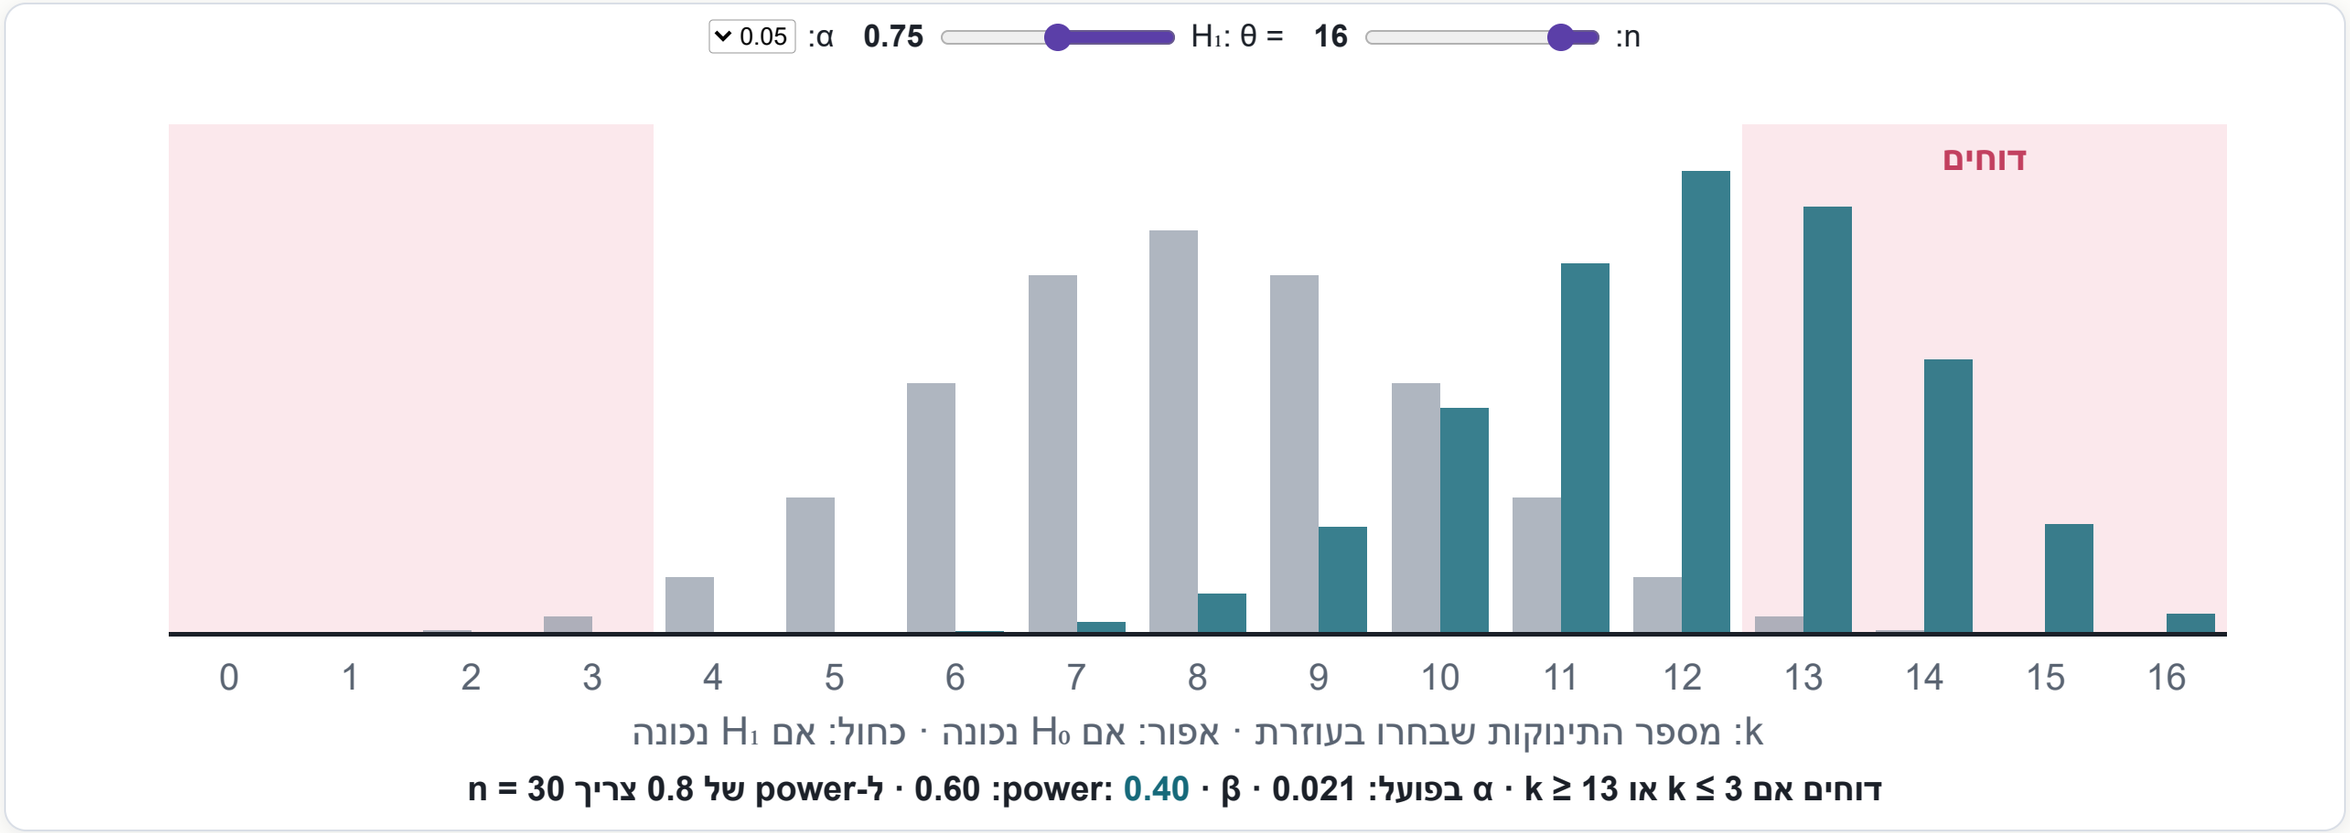
מה ערך p אומר, ומה לא

- p **הוא** $P(\text{נתונים קיצוניים לפחות כמו שלנו} \mid H_0)$.
- p **אינו** $P(H_0 \mid \text{נתונים})$. זה ה-**confusion of the inverse** מהבדיקה הרפואית בשבוע שעבר, בדיוק אותה טעות.
- **לא מובהק אינו "אין אפקט".** 7 מתוך 10 לא מובהק, ועדיין $\hat{\theta} = 0.7$. פשוט אין מספיק נתונים.
- **מובהק אינו "אפקט גדול".** בלידות של Laplace $\hat{\theta} = 0.51$, ו-p קטן מ-10^{-40}. עם n ענק, כל הבדל זעיר מובהק.
- **הקשר לרווח הסמך:** ערך שנמצא מחוץ לרווח סמך 95% יידחה בבדיקה עם $\alpha = 0.05$, בקירוב. הרווח מראה את כל הערכים שלא היינו דוחים.

Neyman ו-Pearson במספרים

- **לפני** שאוספים נתונים: $H_0 : \theta = 0.5$, ו-H_1: לתינוקות יש העדפה, נניח $\theta = 0.75$.
- $\alpha = 0.05$. עם 16 תינוקות, דוחים את H_0 אם $k \leq 3$ או $k \geq 13$. בדיוק עם הכלל הזה, α בפועל הוא 0.021.
- **power**: אם באמת $\theta = 0.75$, ההסתברות ש-k ייפול באזור הדחייה. כאן: **0.40**.
- כלומר, גם אם לתינוקות יש העדפה אמיתית, ב-60% מהניסויים כאלה לא נדחה את H_0 (טעות מסוג II).
- **כמה תינוקות צריך** בשביל **power** של 80%? זו השאלה של Bernoulli על הכד, ועכשיו יש לה כלי.

α, β ו-power בהדגמה



האפור תחת H_0 באזור הדחייה הוא α. הכחול באזור הדחייה הוא ה-**power**, והכחול מחוצה לו הוא β. הגדילו את n, או קרבו את H_1 ל-0.5.

Student: הבעיה

- William Sealy Gosset, כימאי במבשלת Guinness בדבלין. השווה זני שעורה ותרביות שמרים. כל ניסוי יקר, ולכן קטן.
- Guinness אסרה על עובדיה לפרסם, אז ב-1908 פרסם בשם העט **Student**.

> יש ניסויים שקשה לחזור עליהם פעמים רבות. במקרים כאלה צריך לפעמים לשפוט את מידת הוודאות של התוצאות מתוך מדגם קטן מאוד, **שהוא עצמו העדות היחידה לשונות**. [...] ידוע היטב ששיטת העקומה הנורמלית אמינה רק כשהמדגם "גדול", אבל איש עוד לא אמר לנו בבירור איפה עובר הגבול בין "גדול" ל"קטן".
>
> — Student, *The Probable Error of a Mean*, 1908

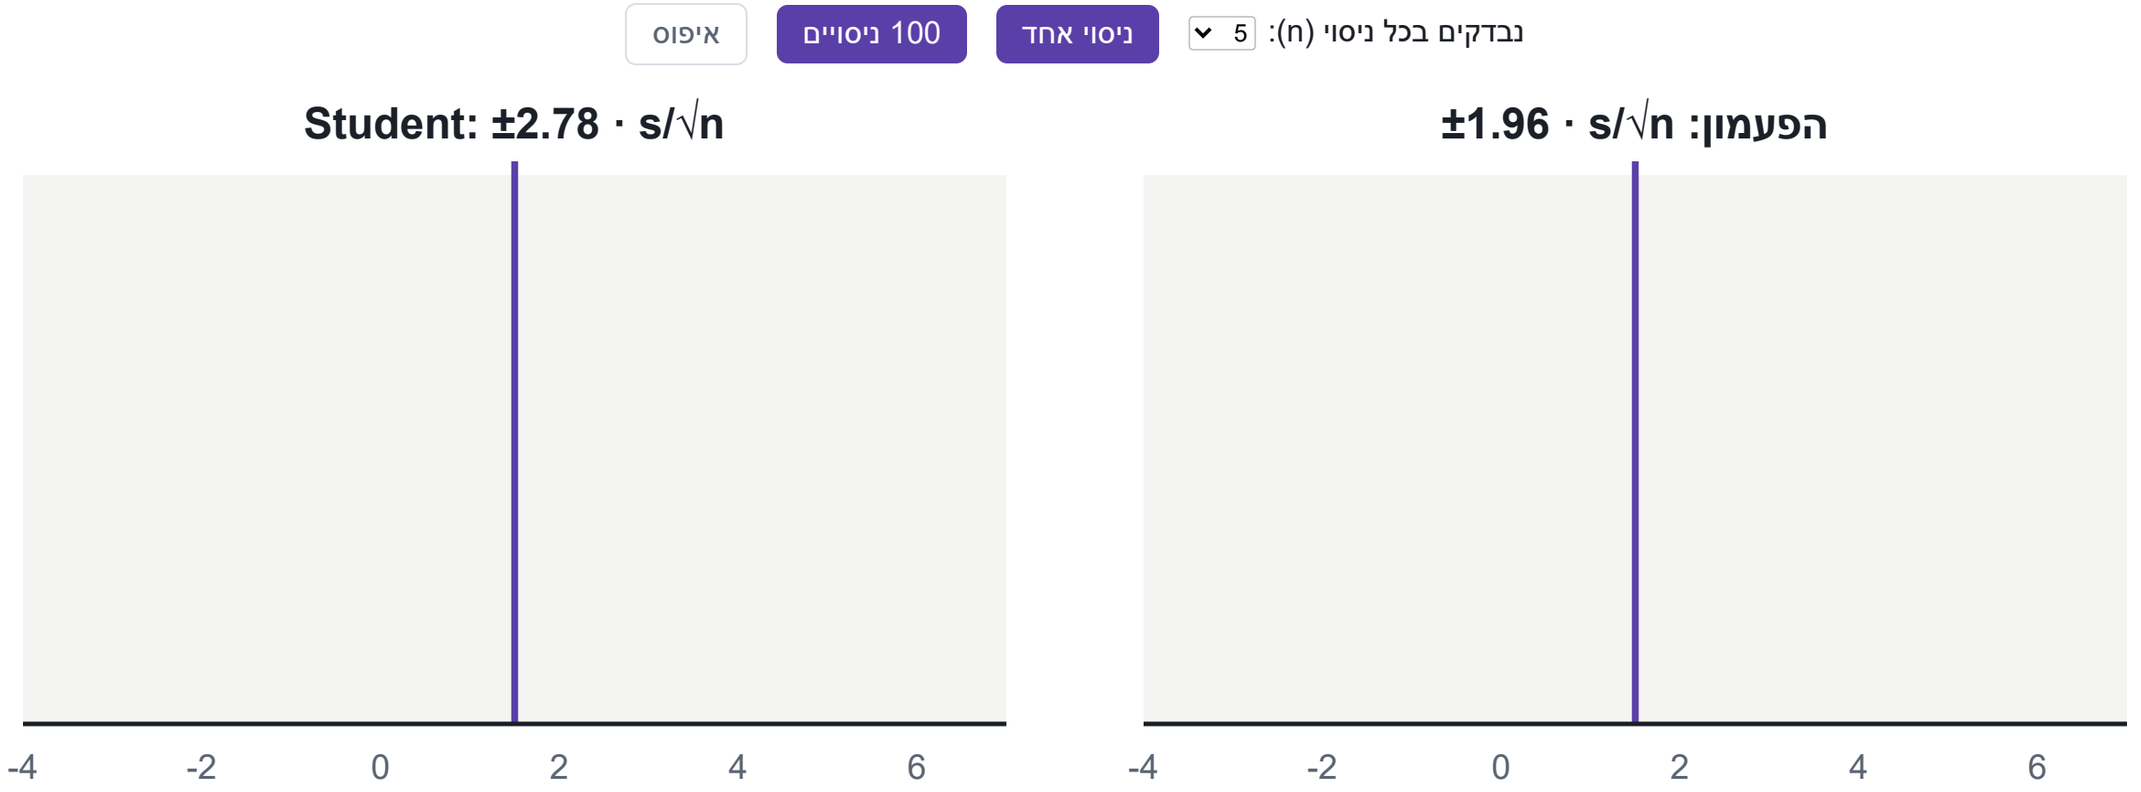
מה Student קירב, ולמה

לרגע יוצאים מ-Bernoulli אל מדידות רציפות: יבול, שעות שינה, זמני תגובה.

- רווח הסמך לממוצע הוא $\bar{y} \pm 1.96 \cdot \sigma/\sqrt{n}$. הפעמון של Laplace מבטיח אותו **אם יודעים את** σ, את סטיית התקן באוכלוסייה.
- אבל σ לא ידוע. מציבים במקומו את s, סטיית התקן של המדגם. **אותו פלאג-אין כמו ב-Wald.**
- במדגם של 5, גם s רועש. לפעמים הוא יוצא קטן, והרווח צר מדי. התוצאה: בטחון שאין לנו.
- Student חישב את ההתפלגות המדויקת של $t = \dfrac{\bar{y} - \mu}{s/\sqrt{n}}$: פעמון עם **זנבות עבים יותר**, שתלוי ב-$n - 1$ (**degrees of freedom**).

n	3	5	10	30	∞
במקום 1.96	4.30	2.78	2.26	2.05	1.96

Student בהדגמה



אותם מדגמים בדיוק בשני הצדדים. ההבדל היחיד הוא המכפיל. עם $n = 3$ או $n = 5$, הפעמון מבטיח 95% ומספק פחות. עם $n = 30$ ההבדל כמעט נעלם.

הלקח של Student, בחזרה ב-Bernoulli

- ב-Bernoulli אין σ נפרד: ה-SE נקבע על ידי θ. לכן אין שם t.
- אבל המחלה זהה: **מציבים אומדן במקום הערך האמיתי, ומתנהגים כאילו הוא מדויק.** ב-Wald זה $\hat{\theta}$, ובממוצע זה s.
- עם הרבה נתונים זה לא משנה. עם מעט נתונים, הקירוב מבטיח יותר ממה שהוא מקיים. 10 מתוך 10 הוא המקרה הקיצוני.
- התרופה בשני המקרים: לחשב את ההתפלגות של השיטה **בדיוק**, בלי להסתמך על פעמון. Student עשה זאת לממוצע, וההתפלגות הבינומית עושה זאת ל-Bernoulli (כמו בהדגמה של ערך ה-p).
- את המבחן עצמו, **t-test**, נפגוש בשבוע 5, כשנשווה בין קבוצות.

מה עונה על מה

השאלה	הכלי	Bernoulli-ב
מה האומדן?	MLE	$\hat{\theta} = k/n$
כמה הוא היה משתנה בין מדגמים?	**standard error**	$\sqrt{\hat{\theta}(1-\hat{\theta})/n}$
איזה טווח של ערכים מתיישב עם הנתונים?	רווח סמך	$\hat{\theta} \pm 1.96\,\widehat{SE}$
האם זה יכול להיות מקרה?	ערך p	$P(\text{קיצוני לפחות כך} \mid H_0)$
איזה כלל החלטה, וכמה נבדקים?	**power** ,β ,α	אזור דחייה מהבינומית
ומה כשהמדגם קטן?	התפלגות מדויקת	בינומית, או לt ממוצע

סיכום

- **MLE:** גוזרים את ה-log-likelihood ומשווים לאפס. ב-Bernoulli: $\hat{\theta} = k/n$.
- **consistent:** ה-MLE מתכנס ל-θ ככל ש-n גדל (חוק המספרים הגדולים).
- **sampling distribution:** איך $\hat{\theta}$ היה מתפזר על פני ניסויים חוזרים. לפי משפט הגבול המרכזי: $\hat{\theta} \dot{\sim} \mathcal{N}(\theta,\ \theta(1-\theta)/n)$.
- **standard error:** סטיית התקן של התפלגות הדגימה. במעשה מציבים בה את $\hat{\theta}$.
- **רווח סמך 95%:** $\hat{\theta} \pm 1.96\ \widehat{SE}$. ה-95% שייך לשיטה, לא לרווח אחד. ב-n קטן ההבטחה נשברת.
- **ערך p:** $P(\text{נתונים קיצוניים לפחות כמו שלנו} \mid H_0)$. לא $P(H_0 \mid \text{נתונים})$, ולא גודל האפקט.
- **Neyman ו-Pearson:** נקבע מראש, α היא ההחמצה, power $= 1 - \beta$ קובע כמה נבדקים צריך.
- **Student:** כשמציבים אומדן במקום הערך האמיתי במדגם קטן, צריך התפלגות מדויקת (t), אחרת הוודאות מזויפת.