אוניברסיטת תל אביב
בעקבות הלא נודע

הערכה שכיחותנית של פרמטר ברנולי

MLE, רווח סמך ובדיקת השערות

פרופ׳ ניצן שחר

הערכת פרמטר בגישה השכיחותנית

נתון: n תצפיות בלתי-תלויות מתוך $\text{Bernoulli}(\theta)$, מתוכן k הצלחות. כיצד נסיק על הפרמטר הקבוע (אך הלא-ידוע) θ?

- **אמידה נקודתית** (MLE): עבור איזה ערך של θ התצפיות שקיבלנו הן הסבירות ביותר?
- **בדיקת השערות** (p-value): בהנחה שהשערת האפס ($\theta = \theta_{\text{null}}$) נכונה, עד כמה התצפיות שלנו (או קיצוניות מהן) מפתיעות?
- **אמידה ברווח** (רווח בר-סמך / CI): מהו טווח ערכי הפרמטר עבורו ב-X% מהמחקרים הטווח יכיל את θ האמיתי?

💡 **תזכורת – מה עשינו בגישה הבייסיאנית:**
הערכנו עבור כל ערך אפשרי של θ את הסיכוי (צפיפות ההסתברות) שהוא הערך החבוי, בהינתן הנתונים והפריור. מתוך התפלגות זו מצאנו את הערך הסביר ביותר (MAP) ואת הטווח שבו נמצא θ בהסתברות של $X\%$ (Credible Interval / HDI).

נראות מקסימלית

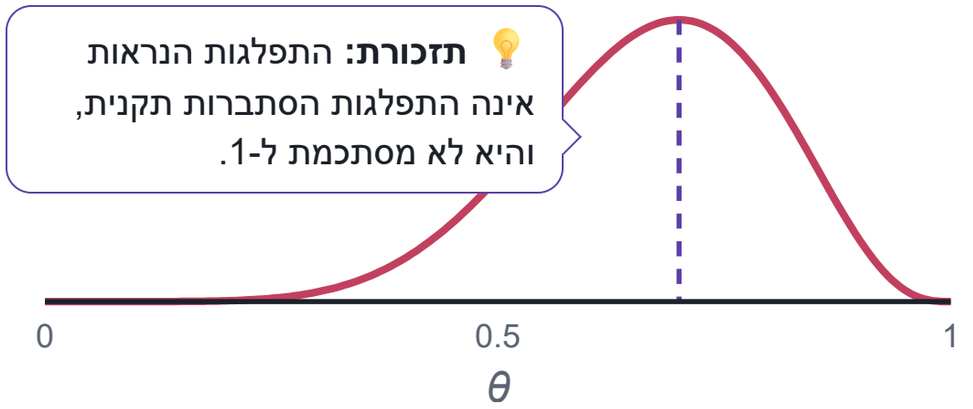
מה האומדן? הערך של θ שהנתונים תומכים בו הכי הרבה: MLE.

נראות מקסימלית

נראות מקסימלית (maximum likelihood estimate; MLE)

ה-MLE הוא הערך של הפרמטר שבו פונקציית ה-likelihood הכי גבוהה.

דוגמה להתפלגות נראות לפרמטר ברנולי:



מחושב על ידי:

$$\mathcal{L}(\theta) = \theta^k(1-\theta)^{n-k}$$

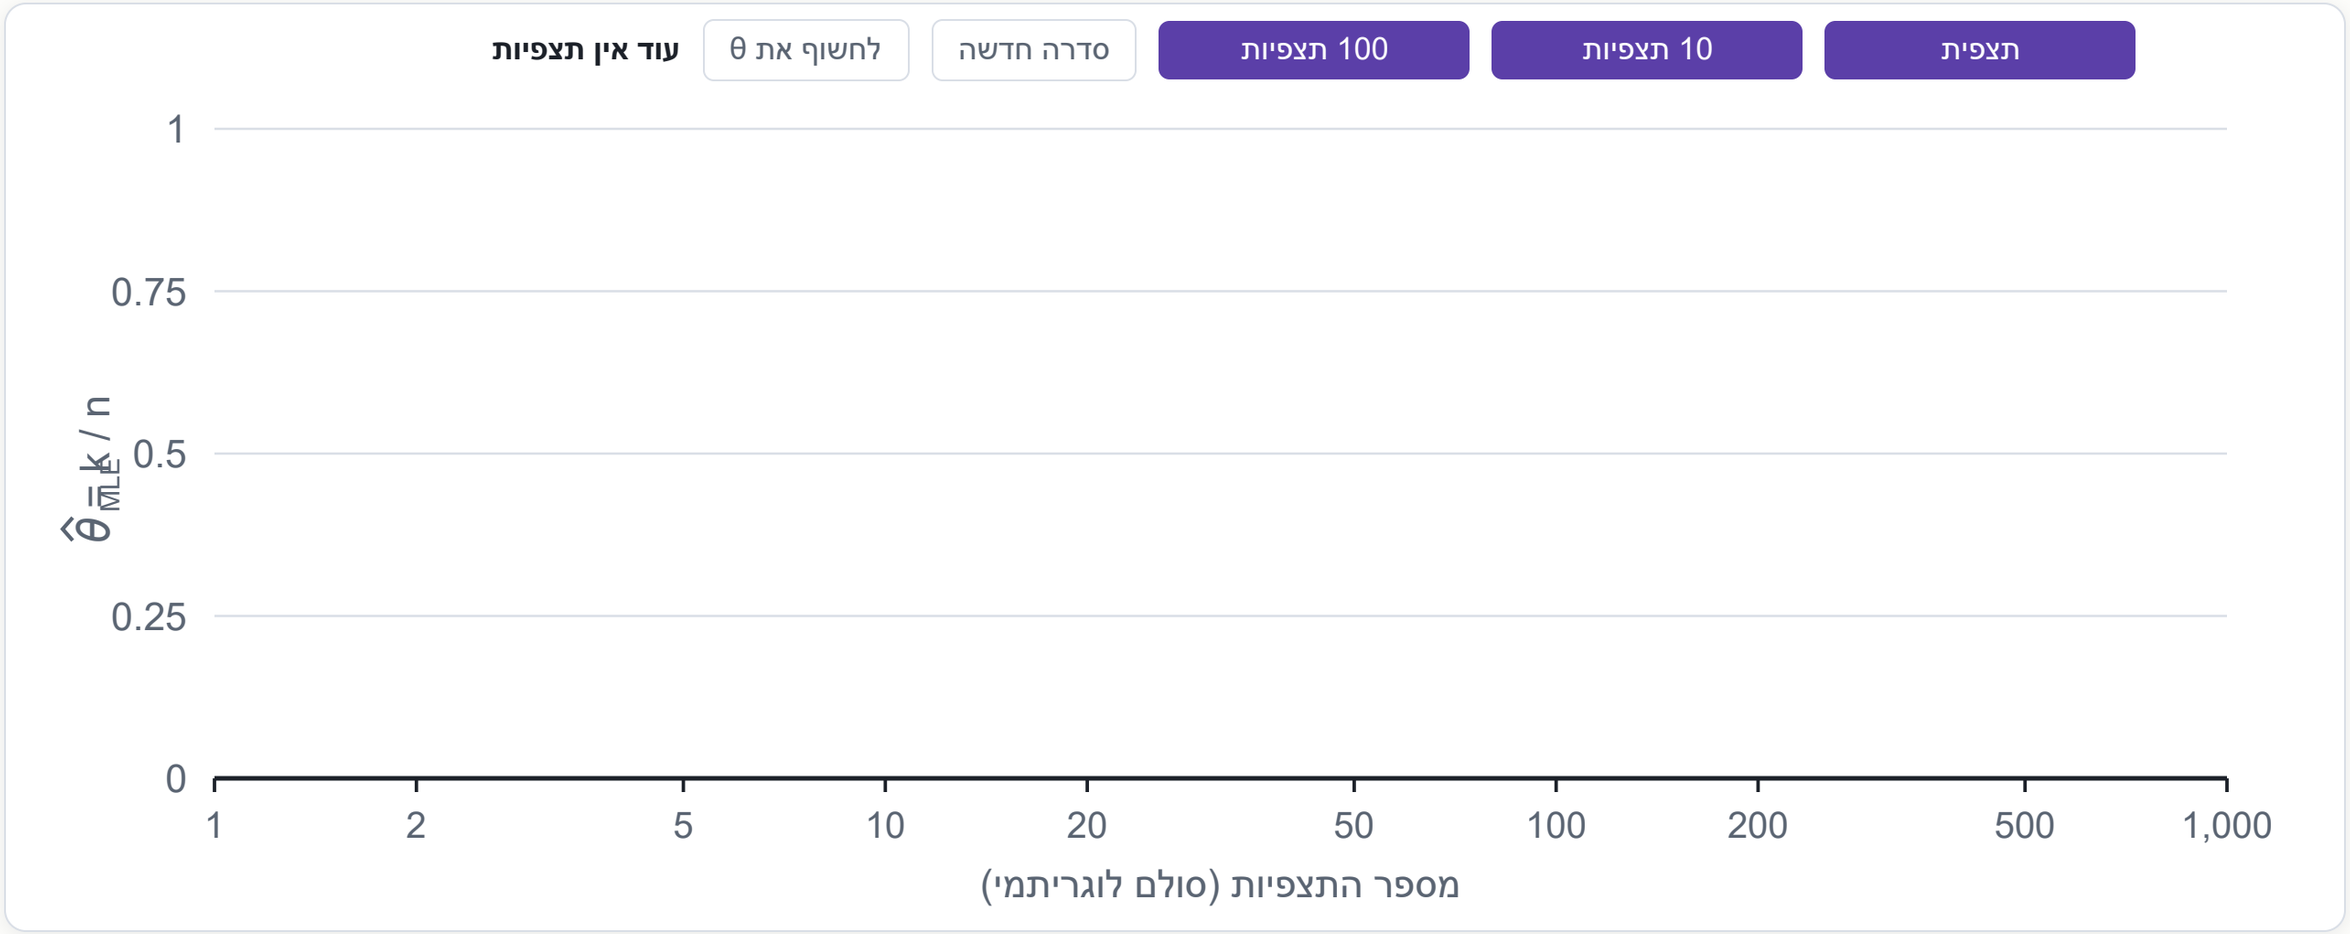
חישוב מהיר:

ה-$\hat{\theta}_{\mathrm{MLE}}$ הוא פשוט שיעור ההצלחות:

$$\hat{\theta}_{\mathrm{MLE}} = \frac{k}{n}$$

כשמדובר באומדן MLE של פרמטר, יופיע הסימון $\hat{\theta}_{\mathrm{MLE}}$ (תטא עם כובע)

נראות מקסימלית



כל תצפית חדשה מעדכנת את $\hat{\theta}_{\mathrm{MLE}}$. המחשב יודע את θ האמיתי, ו"לחשוף את θ" מראה אותו. "סדרה חדשה" מתחילה ניסוי חדש ומשאירה את הקודמים באפור.

נראות מקסימלית

- **התכנסות במדגם אינסופי:** ככל שנגדיל את מספר התצפיות ($n \to \infty$), ובהנחה שהמודל המייצר קבוע והתצפיות בלתי-תלויות, אומדן ה-$\hat{\theta}_{\mathrm{MLE}}$ ילך ויתקרב לפרמטר החבוי θ (בניסוי ברנולי, הדבר נובע ישירות מחוק המספרים הגדולים).
- **הבעיה:** מחקר בודד עם n תצפיות סופיות מפיק לנו אומדן נקודתי בודד (Point estimate). מכיוון שהמדגם סופי, האומדן שלנו כמעט תמיד יסטה במידה מסוימת מ-θ. כיצד נוכל לכמת את אי-הוודאות?

💡 **תזכורת – מה עשינו בגישה הבייסיאנית?**
הערכנו עבור כל ערך אפשרי של θ את הסיכוי (צפיפות ההסתברות) שהוא הערך החבוי. רוחב ההתפלגות הפוסטריורית עצמה מבטא את חוסר הוודאות.

התפלגות דגימה

איך האומדן היה מתפזר, אם היינו חוזרים על הניסוי שוב ושוב.

התפלגות דגימה

הגדרה · התפלגות דגימה (sampling distribution)

תחת ההנחה שהפרמטר באוכלוסייה קבוע ושווה לערך "בר ההפרכה" שקבענו (θ_{null}), ואילו חזרנו על הניסוי אינסוף פעמים באותו גודל מדגם (n), זוהי התפלגות ההסתברות של כל אומדני המדגם ($\hat{\theta}_{\text{MLE}}$) שהיינו מקבלים.

- דמיינו שהפרמטר באוכלוסייה שווה ל-θ_{null}, ושחוזרים על אותו ניסוי שוב ושוב, בכל פעם n תצפיות, ובכל פעם מחשבים $\hat{\theta}_{\text{MLE}}$.
- כש-n גדול מספיק, צורת התפלגות הדגימה היא פעמונית (לפי משפט הגבול המרכזי של לפלס), וככל ש-n גדל, הפעמון צר יותר.
- התפלגות הדגימה היא התפלגות הסתברות תקנית שמסתכמת ל-1 (ומכאן היא מאפשרת לנו לחשב רווח בר-סמך ו-p-value).

התפלגות דגימה



כל ניסוי: n תצפיות, ומהן $\hat{\theta}_{\text{MLE}}$ אחד. כל נקודה היא ניסוי אחד, והנקודות נערמות מעל הערך שיצא. כל הנקודות יחד הן **התפלגות הדגימה** של $\hat{\theta}_{\text{MLE}}$. הקו הסגול: θ_{null}.
נסו $n = 1$, אחר כך $n = 5$ עם $\theta = 0.1$, ואז $n = 500$.

התפלגות דגימה

רוחב (פיזור): סטיית התקן של התפלגות הדגימה נקראת טעות תקן (**Standard Error**).
בהתפלגות ברנולי היא מחושבת כך:

$$SE_{\text{null}} = \sqrt{\frac{\theta_{\text{null}}(1-\theta_{\text{null}})}{n}}$$

בהתפלגות ברנולי, מאחר שערך ה-θ_{null} ידוע לנו, לא מדובר באומדן אלא בהערכה מדויקת. כפי שנראה בהמשך, זהו מקרה ייחודי, ולרוב נאלץ להסתפק באומדנים.

אזור הקבלה ו-p-value

אם אין אפקט, עד כמה מה שראינו מפתיע?

אזור הקבלה ו-p-value

הגדרה · אזור קבלה (acceptance region)

הטווח סביב θ_{null} שבו נופלים $X\%$ מערכי ה-$\hat{\theta}_{\text{MLE}}$ של מחקרים חוזרים (אותו מחקר, שוב ושוב, באותו גודל מדגם n), אם θ_{null} הוא הפרמטר החבוי (האמיתי).

- דמיינו שהפרמטר באוכלוסייה שווה ל-θ_{null}, ושחוזרים על המחקר שוב ושוב. בכל מחקר מחשבים $\hat{\theta}_{\text{MLE}}$, והערכים מתפזרים סביב θ_{null}: זו התפלגות הדגימה.
- התפלגות הדגימה היא התפלגות הסתברות (השטח שלה הוא 1), ולכן אפשר לסמן בה את הטווח האמצעי שבו נופלים $X\%$ מערכי ה-$\hat{\theta}_{\text{MLE}}$, בהינתן שהערך בר ההפרכה נכון. זה אזור הקבלה.
- אם ה-$\hat{\theta}_{\text{MLE}}$ שקיבלנו במחקר שלנו נפל מחוץ לאזור הקבלה, לא סביר ש-θ_{null} הוא הערך האמיתי באוכלוסייה.

אזור הקבלה ו-p-value

הגדרה · p-value

ההסתברות לקבל תוצאה קיצונית לפחות כמו זו שראינו, אם ההשערה ברת-ההפרכה נכונה.

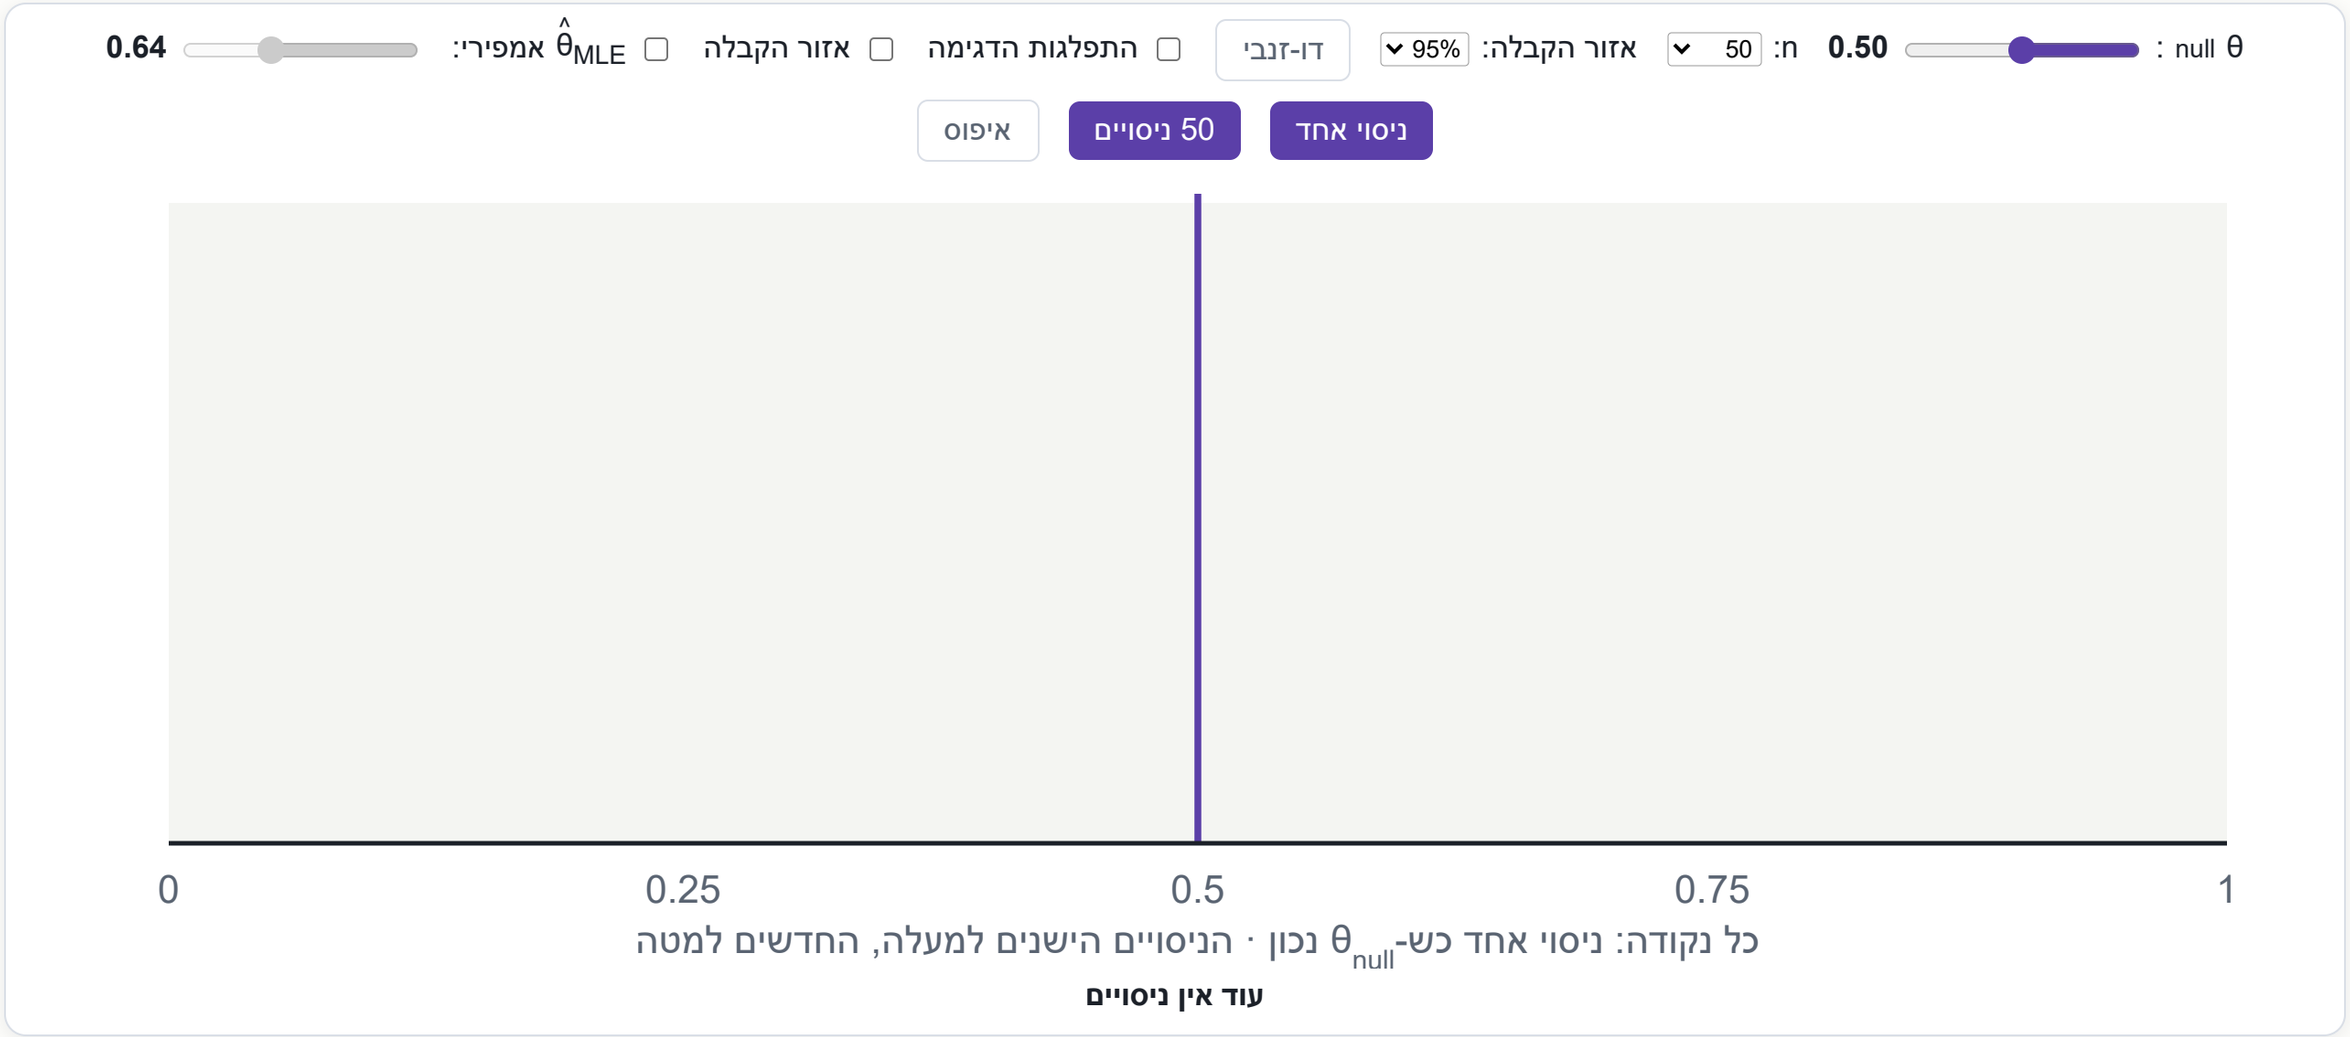
- מאחר שהתפלגות הדגימה היא התפלגות הסתברות תקנית, ניתן לחשב את החלק ממנה שרחוק מ-θ_{null} לפחות כמו ה-$\hat{\theta}_{\text{MLE}}$ שלנו (בשני הצדדים).
- שטח זה הוא p: ההסתברות לקבל $\hat{\theta}_{\text{MLE}}$ אמפירי שווה לערך שקיבלנו או קיצוני ממנו.

📖 **significant** /sɪgˈnɪf.ɪ.kənt/

שם תואר

מַשְׁמָעוּתִי | חָשׁוּב | גָּדוֹל | רַב | נִכָּר | מַהוּתִי

אזור הקבלה ו-p-value



אזור הקבלה ו-p-value

- p **הוא** $P(\text{נתונים קיצוניים לפחות כמו שלנו} \mid H_0)$.
- p **אינו** $P(\text{נתונים} \mid H_0)$. זה ה-**confusion of the inverse** מהבדיקה הרפואית בשבוע שעבר, בדיוק אותה טעות.
- **לא משמעותי אינו "אין אפקט".** 7 מתוך 10 לא משמעותי, ועדיין $\hat{\theta}_{\text{MLE}} = 0.7$. פשוט אין מספיק נתונים.
- **משמעותי אינו "אפקט גדול".** בסקר של מיליון איש, 51% מול 49% נותן p קטן מ-10^{-80}. עם n ענק, כל הבדל זעיר משמעותי.

רווח בר-סמך

טווח של ערכים שמתיישבים עם הנתונים.

רווח בר-סמך (Confidence Interval)

הגדרה · confidence interval

טווח ערכים סביב אומדן המדגם ($\hat{\theta}_{\text{MLE}}$), כך שאם נחזור על המחקר אינסוף פעמים ונחשב בכל פעם טווח כזה, ב-$X\%$ מהמחקרים הוא יכיל את הפרמטר החבוי θ.

- **המטרה המקורית של רווח בר-סמך היא אמידה (Estimation), לא בדיקת השערות:**
  - בבדיקת השערות (p-value ואזור קבלה) השאלה בינארית (כן/לא): האם אפשר לפסול את θ_{null}?
  - ברווח בר-סמך השאלה כמותית (כמה?): אין לנו θ_{null} בראש, ושואלים מהו טווח הערכים הסביר ל-θ החבוי. כלומר, מה גודל האפקט ומה רמת הדיוק שלנו.
- **אז למה במאמרים בודקים אם 0 (או θ_{null}) נמצא בתוך הרווח? בגלל הדואליות:** הרווח בנוי מאותו "סרגל" של התפלגות הדגימה, ולכן הוא מכיל את כל ערכי ה-θ_{null} שלא היינו דוחים. כך רואים גם את גודל האפקט, וגם, על הדרך, אם θ_{null} (למשל 0 בהפרש ממוצעים, או 0.5 במטבע) נמצא מחוץ לרווח, כלומר אם התוצאה מובהקת ($p < \alpha$).

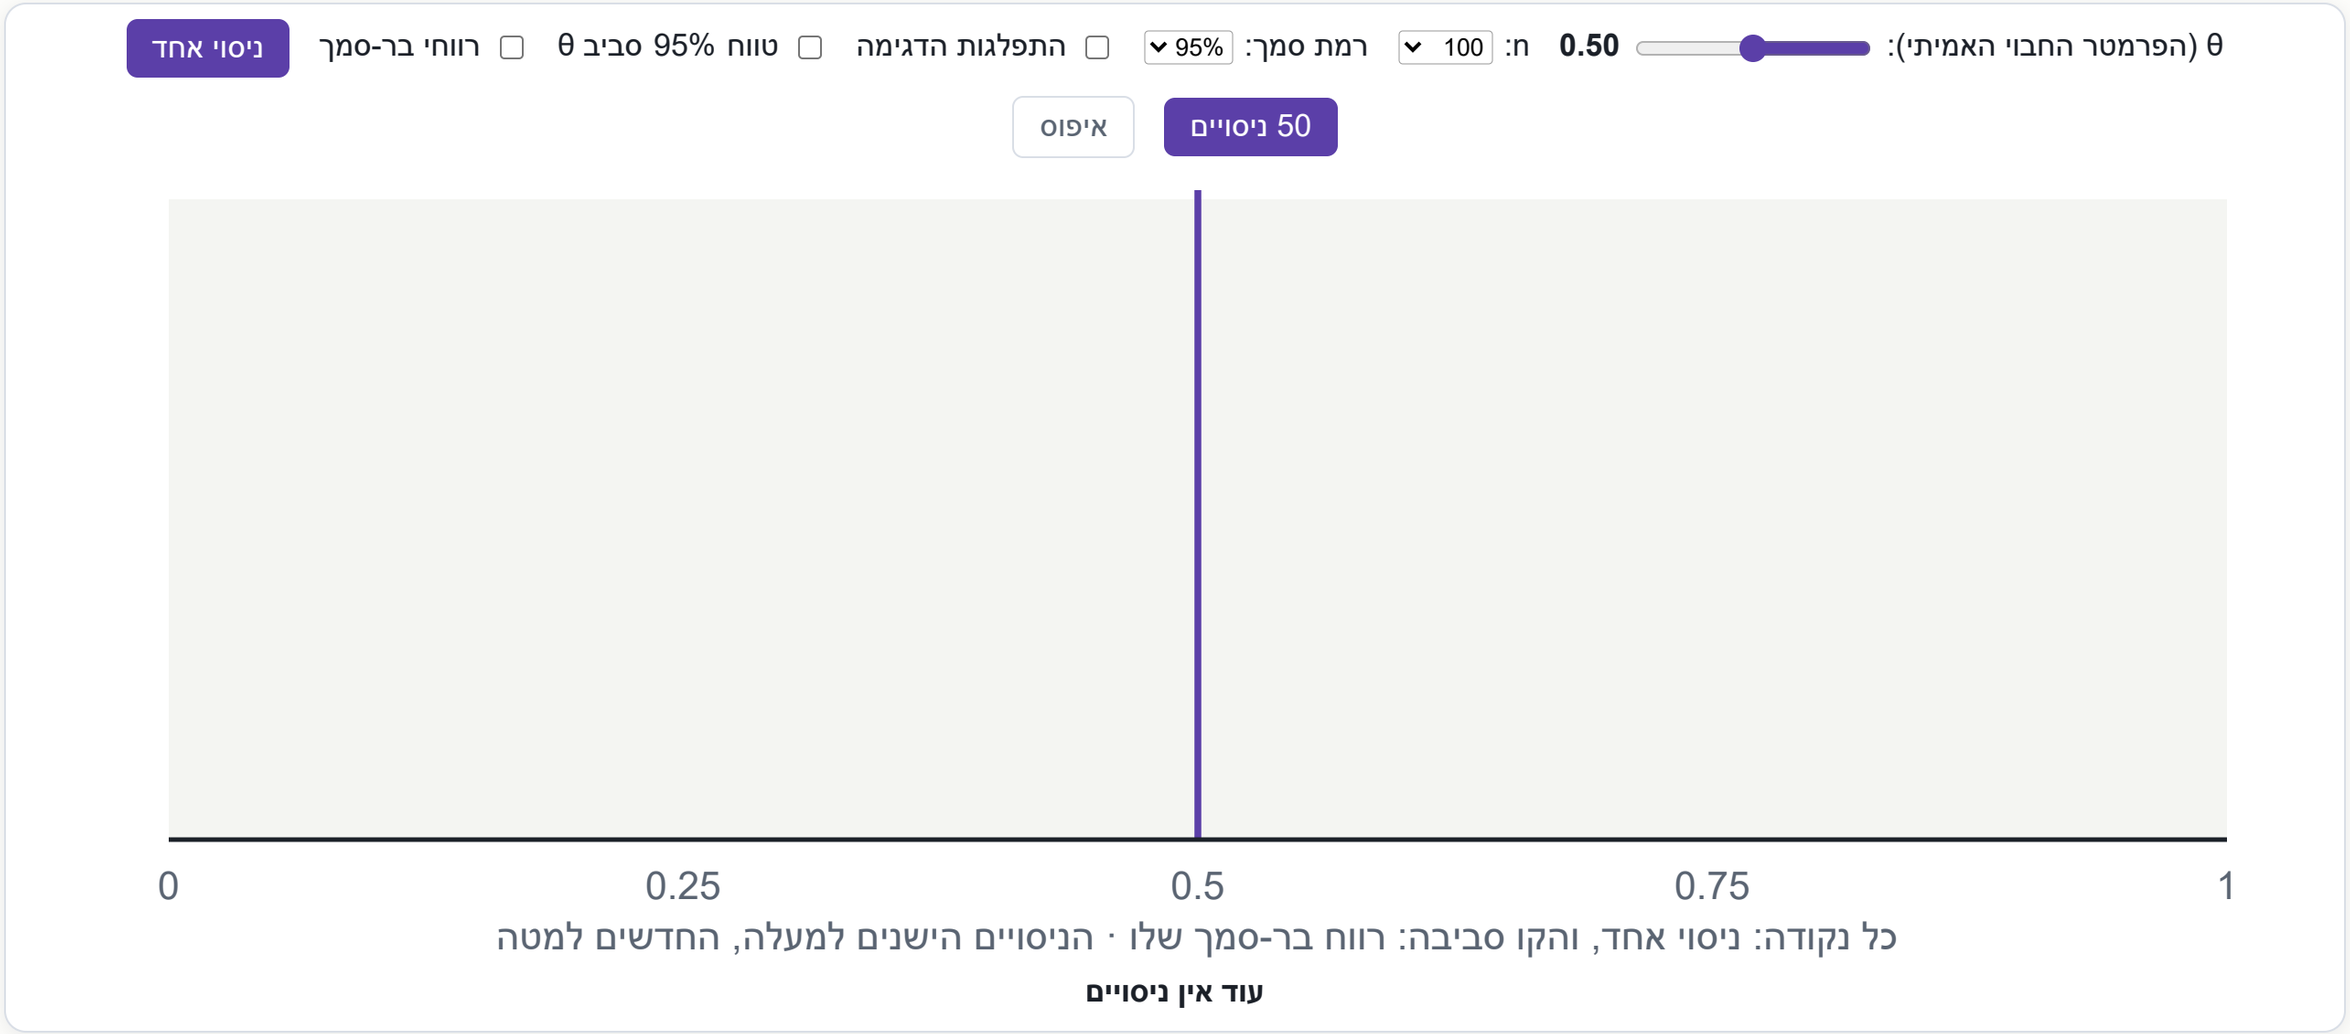
רווח בר-סמך (Confidence Interval)

הגדרה · confidence interval

טווח ערכים סביב אומדן המדגם ($\hat{\theta}_{\text{MLE}}$), כך שאם נחזור על המחקר אינסוף פעמים ונחשב בכל פעם טווח כזה, ב-$X\%$ מהמחקרים הוא יכיל את הפרמטר החבוי θ.

- כדי לבנות רווח בר-סמך אנו משאילים את המנגנון של התפלגות הדגימה ואזור הקבלה, שמאפשר לנו לבנות טווח שב-$X\%$ מהמחקרים יכיל את ערך הפרמטר החבוי θ.
- כשבנינו אזור קבלה, הנחנו שערך הפרמטר החבוי הוא θ_{null} קבוע מראש; כעת, אנו רוצים שהטווח יתפוס את θ האמיתי החבוי בטבע.
- לשם כך אנו בונים רווח שמרכזו הוא אומדן המדגם $\hat{\theta}_{\text{MLE}}$, ורוחבו נגזר מנוסחת התפלגות הדגימה תוך הצבת $\hat{\theta}_{\text{MLE}}$ (כדי לקבל אומדן לרוחב).

רווח בר-סמך



מטרת הרווח היא לתפוס את θ החבוי: ב-$X\%$ מהניסויים אומדן ה-$\hat{\theta}_{\mathrm{MLE}}$ נופל בתוך הטווח המוצלל סביב θ, ולכן הרווח סביבו (בירוק) מצליח להכיל את θ. רק ב-$(100-X)\%$ מהניסויים (באדום) הרווח מפספס את θ.

שימוש במנגנון התפלגות הדגימה

התפלגות דגימה קיימת רק סביב פרמטר קבוע, ולעולם לא סביב אומדן, שהוא תוצאה אקראית חד-פעמית. ובכל זאת, בפועל, אנו נשתמש בהתפלגות הדגימה באופנים הבאים:

ההיפותטית · סביב θ_{null}

ניסוי מחשבתי: איך הייתה נראית אילו $\theta_{\text{true}} = \theta_{\text{null}}$? המרכז והרוחב ($SE_{\text{null}}$) ידועים. ממנה מחשבים אזור קבלה ו-p-value.

האמיתית · סביב θ_{true}

היחידה שקיימת בטבע: כך היו מתפזרים ערכי ה-$\hat{\theta}_{\text{MLE}}$ אילו חזרנו על הניסוי שוב ושוב. היא מאפשרת לבנות רווח בר-סמך שמרכזו $\hat{\theta}_{\text{MLE}}$, וכך מתקבלים שני אומדנים: נקודה (המרכז) וטווח (הרווח).

למה משתמשים לעיתים בהתפלגות t?

- כשבודקים ממוצע של משתנה רציף (למשל ציון בשאלון), רוחב התפלגות הדגימה תלוי בפיזור באוכלוסייה. את הפיזור הזה איננו יודעים, ולכן אומדים אותו מהמדגם.
- האמידה הזו מוסיפה אי-ודאות, בעיקר במדגם קטן, והתפלגות t היא פעמון עם זנבות רחבים יותר שמתחשב בה. בברנולי הרוחב נקבע מהפרמטר עצמו, ולכן אין בה צורך.

מאמר לדוגמה

תינוקות בוחרים בין דמות שעוזרת לדמות שמפריעה, וכל הכלים על הנתונים שלהם.

מאמר לדוגמה

לפתוח ב-YouTube

מאמר לדוגמה

- Hamlin, Wynn ו-Bloom (2007): תינוקות בני 10 חודשים צפו בדמות "עוזרת" (משולש) ובדמות "מפריעה" (ריבוע), ואחר כך בחרו באחת. הגירויים המקוריים
- **14 מתוך 16** בחרו בעוזרת.
- המודל: כל תינוק הוא תצפית אחת, $y_i \sim \text{Bernoulli}(\theta)$, ו-$\theta$ הוא הסיכוי שתינוק יבחר בעוזרת.

Hamlin, J. K., Wynn, K., & Bloom, P. (2007). Social evaluation by preverbal infants. *Nature, 450*, 557–559. doi.org/10.1038/nature06288

מאמר לדוגמה

- 14 מתוך 16 בחרו בעוזרת: $\hat{\theta}_{\mathrm{MLE}} = 14/16 = 0.875$.
- ההשערה ברת-ההפרכה: לתינוקות אין העדפה, $\theta_{\mathrm{null}} = 0.5$. אם היא נכונה, $SE_{\mathrm{null}} = \sqrt{0.5 \cdot 0.5/16} = 0.125$.
- כמה רחוק ה-$\hat{\theta}_{\mathrm{MLE}}$ שלנו: $z = \dfrac{0.875 - 0.5}{0.125} = 3$. בקירוב הפעמון, $p = 0.0027$.
- בחישוב מדויק בהתפלגות הבינומית: $p = 0.0042$. עם $\alpha = 0.05$, $p < \alpha$: ה-$\hat{\theta}_{\mathrm{MLE}}$ מחוץ לאזור הקבלה של 95%, והתוצאה **משמעותית**.

מאמר לדוגמה

- $\widehat{SE} = \sqrt{0.875 \cdot 0.125/16} = 0.083$.
- רווח בר-סמך של 95%: $0.875 \pm 1.96 \cdot 0.083 = 0.875 \pm 0.16$, כלומר $[0.71,\ 1.04]$.
- $\theta_{\text{null}} = 0.5$ מחוץ לרווח, ולכן גם כך היינו דוחים אותו, כמו שראינו ב-p.
- הגבול העליון גדול מ-1, ו-θ לא יכול להיות גדול מ-1. זה סימן שעם 16 תינוקות הקירוב כבר חורק.

סיכום

- **MLE:** ה-θ שבו הנראות (**likelihood**) הכי גבוהה. בברנולי $\hat{\theta}_{\mathrm{MLE}} = k/n$, והוא מתכנס ל-$\theta$ ככל ש-n גדל.
- **התפלגות דגימה:** כך היו מתפזרים ערכי ה-$\hat{\theta}_{\mathrm{MLE}}$ במחקרים חוזרים, סביב פרמטר קבוע. היא פעמונית (משפט הגבול המרכזי), ורוחבה, טעות התקן (SE), קטן ככל ש-n גדל.
- **אזור הקבלה ו-p-value:** סביב θ_{null}, אזור הקבלה הוא הטווח שבו נופלים $X\%$ מערכי ה-$\hat{\theta}_{\mathrm{MLE}}$. p הוא ההסתברות לקבל $\hat{\theta}_{\mathrm{MLE}}$ קיצוני לפחות כמו שלנו, אם θ_{null} נכון. הוא אינו ההסתברות ש-θ_{null} נכון, ואינו גודל האפקט.
- **רווח בר-סמך:** טווח סביב $\hat{\theta}_{\mathrm{MLE}}$, שב-$X\%$ מהמחקרים מכיל את θ החבוי. ה-$X\%$ שייך לשיטה, לא לרווח אחד, וכל θ_{null} שמחוץ לרווח היה נדחה.