אוניברסיטת תל אביב
בעקבות הלא נודע

המפה

שלושה שיעורים, שאלה אחת ושתי דרכים

פרופ׳ ניצן שחר

שאלה אחת

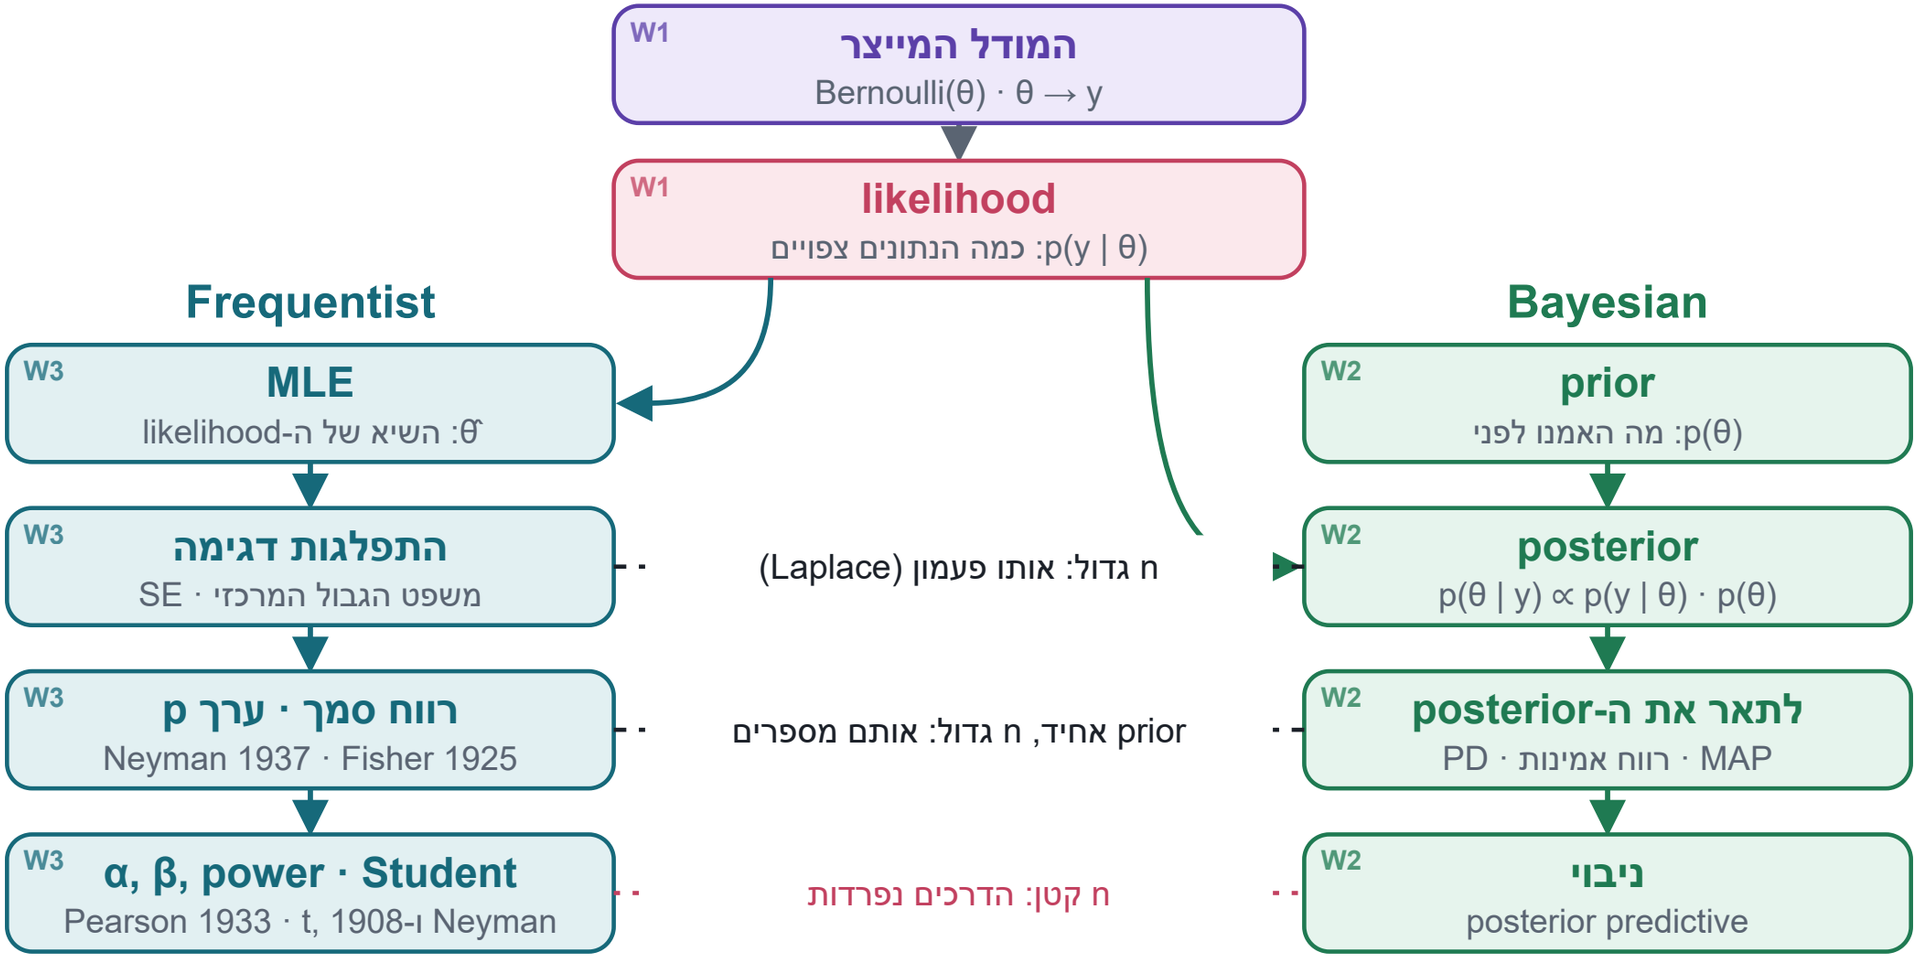
θ · החוקיות החבויה בטבע

הטבע מייצר נתונים ↓ · המדען מסיק אחורה ↑

y · התצפיות שבידינו

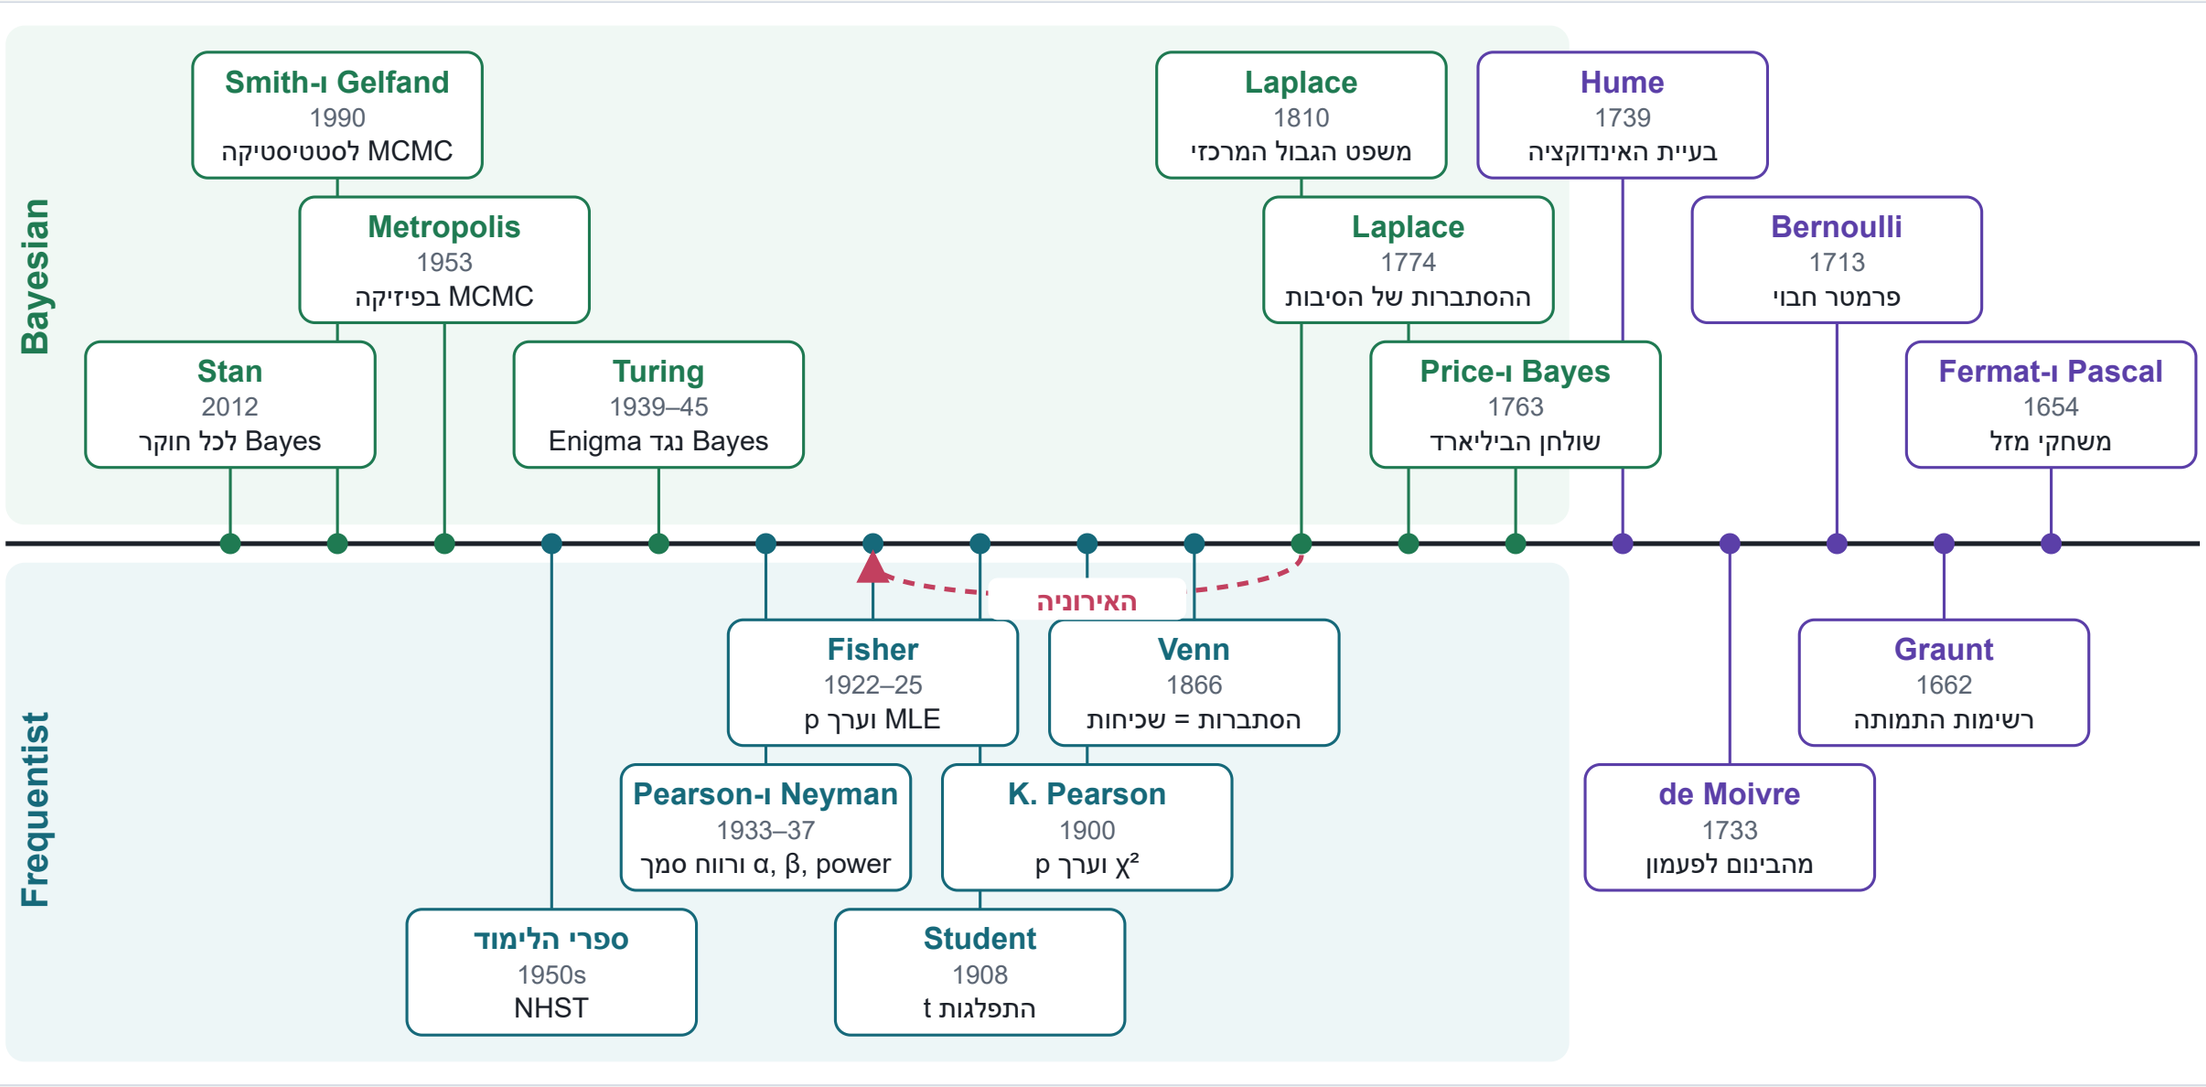
- **מה אפשר לדעת על θ מתוך y, ובאיזו ודאות?** זו השאלה ש-Bernoulli שאל ב-1713.
- כל מה שלמדנו בשלושה שיעורים הוא תשובה לשאלה הזו. יש שתי תשובות, והן מתחילות מאותו מקום.

המפה



לחצו על תיבה כדי לראות מה היא אומרת.

ציר הזמן


Bayesian
Frequentist
Smith-ו Gelfand
1990
MCMC לסטטיסטיקה
Metropolis
1953
MCMC בפיזיקה
Stan
2012
Bayes לכל חוקר
Turing
1939–45
Enigma נגד Bayes
Laplace
1810
משפט הגבול המרכזי
Laplace
1774
ההסתברות של הסיבות
Hume
1739
בעיית האינדוקציה
Bernoulli
1713
פרמטר חבוי
Price-ו Bayes
1763
שולחן הביליארד
Fermat-ו Pascal
1654
משחקי מזל
האירוניה
Fisher
1922–25
p וערך MLE
Venn
1866
הסתברות = שכיחות
Graunt
1662
רשימות התמותה
Pearson-ו Neyman
1933–37
α, β, power ורווח סמך
K. Pearson
1900
p וערך χ^2
de Moivre
1733
מהבינום לפעמון
ספרי הלימוד
1950s
NHST
Student
1908
התפלגות t

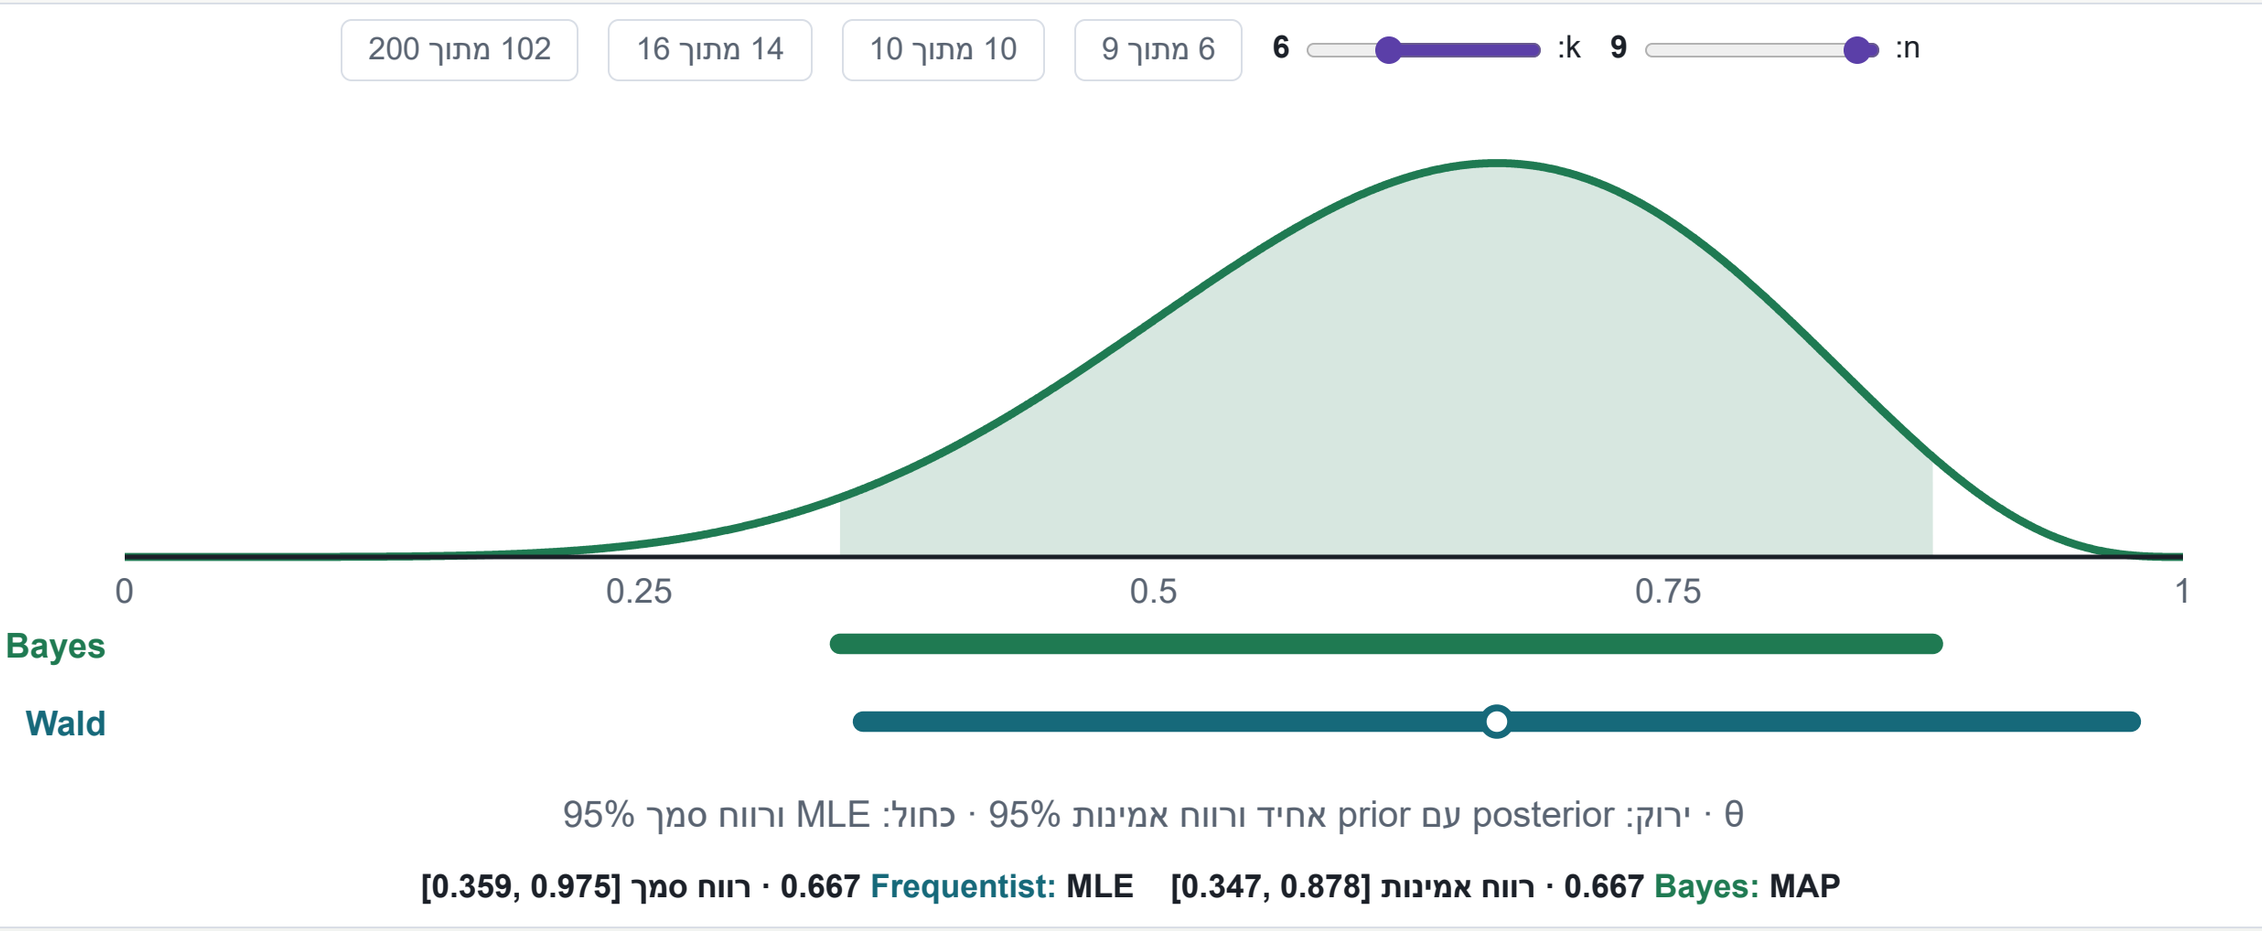
למה התפצלו

- **סובייקטיביות:** ה-**prior** נראה כמו דעה אישית. המאה ה-20 רצתה שאותם נתונים יובילו כל חוקר לאותה מסקנה.
- **שרירותיות:** גם **prior** אחיד הוא בחירה. אחיד על הצלע אינו אחיד על השטח.
- **חישוב:** MLE הוא נגזרת. **posterior** הוא אינטגרל, ובלי מחשב, ברוב המודלים, הוא בלתי אפשרי. רק MCMC (1990) ו-Stan (2012) החזירו את Bayes לשימוש רחב.
- **והאירוניה:** הפעמון ש-Laplace בנה בשביל Bayes נתן לשכיחותנים את הכלי לוותר על ה-**prior**.

ההבדלים

Frequentist	Bayesian	
שכיחות לאורך זמן	מידת ודאות	הסתברות היא
המדגם	הידע שלנו על θ	מה אקראי
התפלגות דגימה	**prior**	מה מצטרף ל-likelihood
SE-ו $\hat{\theta}$	התפלגות על θ	התשובה
θ מהרווחים של השיטה מכסים את 95%	בהסתברות 95%, θ כאן	"95%"
$P(\text{יצוני קי}ext \mid H_0)$	PD ,$P(H \mid y)$	השערות
הקירובים נשברים	עובד, וה-prior משפיע יותר	מדגם קטן

אותם נתונים, שתי תשובות



עם הרבה נתונים שני הרווחים כמעט זהים: זו האירוניה של Laplace, במספרים. עם מעט נתונים, ובמיוחד ב-10 מתוך 10, הם נפרדים.

אותו 95%, שני משפטים

רווח אמינות

"בהינתן הנתונים, בהסתברות 95%, θ נמצא בין 0.35 ל-0.88." משפט על θ.

רווח סמך

"שיטה שבה 95% מהרווחים, על פני ניסויים חוזרים, מכסים את θ, נתנה הפעם $[0.36,\ 0.97]$." משפט על השיטה.

- הטעות הנפוצה ביותר: לקרוא רווח סמך כאילו היה רווח אמינות.
- ואותה טעות בבדיקת השערות: לקרוא את $p = P(\text{נתונים} \mid H_0)$ כאילו היה $P(H_0 \mid \text{נתונים})$.
  זה ה-**confusion of the inverse**.

מי אמר?

את מה שלא ניתן לנו לגזור מראש, נוכל לכל הפחות לחלץ בדיעבד מתוך הניסיון.

מי?

אם יראה אותה שבה, תתעורר בו ציפייה, והוא יוכל לדעת שיש יחס סיכויים של 3 ל-1 שקיימת נטייה לשיבה כזו.

מי?

תורת ההסתברות איננה אלא השכל הישר, מתורגם לחשבון.

מי?

צריך לפעמים לשפוט את הוודאות מתוך מדגם קטן מאוד, שהוא עצמו העדות היחידה לשונות.

מי?

תורת ההסתברות ההפוכה מושתתת על טעות, ויש לדחות אותה כליל.

מי?

נחפש כללים שינחו את התנהגותנו, כך שבטווח הארוך של הניסיון לא נטעה לעתים קרובות מדי.

מי?

לחצו על ציטוט כדי לגלות מי אמר אותו. הצבע מראה לאיזו דרך הוא שייך.

שאלות שמחברות

1. ב-6 מתוך 9, ה-MAP וה-MLE הם אותו מספר. מה בכל זאת שונה ביניהם?
2. למה 10 מתוך 10 מפיל את רווח Wald, אבל לא את ה-**posterior**?
3. הסבירו בשלושה משפטים את האירוניה של משפט הגבול המרכזי.
4. “$p = 0.03$, ולכן יש 3% סיכוי שהשערת האפס נכונה.” מה הטעות, ואיפה פגשנו אותה כבר?
5. Bernoulli שאל כמה שליפות צריך כדי להגיע לוודאות מוסרית. איפה השאלה הזו מופיעה אצל Neyman ו-Pearson?
6. רווח Wald ב-Bernoulli ורווח עם 1.96 במדגם קטן של מדידות סובלים מאותה בעיה. מהי, ומה עשה איתה Student?

מה הלאה

- בשבוע הבא: מדידות רציפות, והתפלגות Gaussian. לה שני פרמטרים, μ ו-σ.
- **המפה לא משתנה.** מודל מייצר, **likelihood**, ואז שתי הדרכים: **posterior** על שני הפרמטרים, או MLE, SE ו-t.
- כל שבוע בקורס יחליף את המודל המייצר. השלד יישאר.

סיכום

- **שאלה אחת:** מה אפשר לדעת על θ החבוי מתוך y הגלוי, ובאיזו ודאות.
- **גזע משותף:** המודל המייצר וה-**likelihood**.
- **Bayesian:** **prior** × **likelihood** → **posterior**, ואז תיאור וניבוי. הסתברות היא ודאות.
- **Frequentist:** MLE → התפלגות דגימה → SE, רווח סמך, ערך p, α, β ו-**power**. הסתברות היא שכיחות.
- **נפגשות:** עם הרבה נתונים ו-**prior** אחיד, כמעט אותן תשובות. **נפרדות:** במדגם קטן.
- **ציר הזמן:** Bayes ← Bernoulli ו-Fisher ← Laplace, Student, Neyman ו-MCMC ← Pearson ו-Stan.