שבוע 4 · Continuous estimates

ה-likelihood של μ ו-σ

מהתצפיות אל הפרמטרים של ההתפלגות הגאוסיינית

פרופ׳ ניצן שחר

הבעיה ההפוכה

$\mu = ?$ · $\sigma = ?$ · חבויים בטבע

▼

$$y \sim \text{Normal}(\mu,\ \sigma)$$

▼

$y_1, y_2, \ldots, y_n$ · התצפיות שבידינו

- במצגת הקודמת הלכנו מ-μ ו-σ אל התצפיות. במחקר יש לנו רק את התצפיות.
- בדיוק כמו בכד של ברנולי: עוברים על ערכים מועמדים של הפרמטר, ושואלים בכמה דרכים כל אחד מהם יכול לייצר את מה שראינו.

ספירת דרכים בלוח

likelihood בלי נוסחה: לוח גלטון שמונח על כל מועמד

ספירת דרכים בלוח



הלוח מהשיעור, עם 5 שורות. מניחים אותו כך שהמרכז שלו על μ מועמד, וסופרים בכמה דרכים כדור יכול ליפול לתא של כל תינוק. התחילו בתינוק אחד, ואחר כך עברו לשניים.

ספירת דרכים בלוח

- לכל ערך מועמד של μ ספרנו בכמה דרכים הלוח יכול לייצר כל תצפית.
- כשיש כמה תצפיות **כופלים**: כל דרך לתינוק הראשון משתלבת עם כל דרך לתינוק השני. בדיוק כמו בשבילי הנתונים של השבוע הראשון.
- המועמד שיש לו הכי הרבה דרכים הוא $\mu = 3$: בדיוק הממוצע של 2.6 ו-3.4.
- זו התפלגות ה-**likelihood**: עד כמה התצפיות צפויות, בהינתן כל ערך אפשרי של הפרמטר.

likelihood רציף

מהלוח אל פונקציית הצפיפות

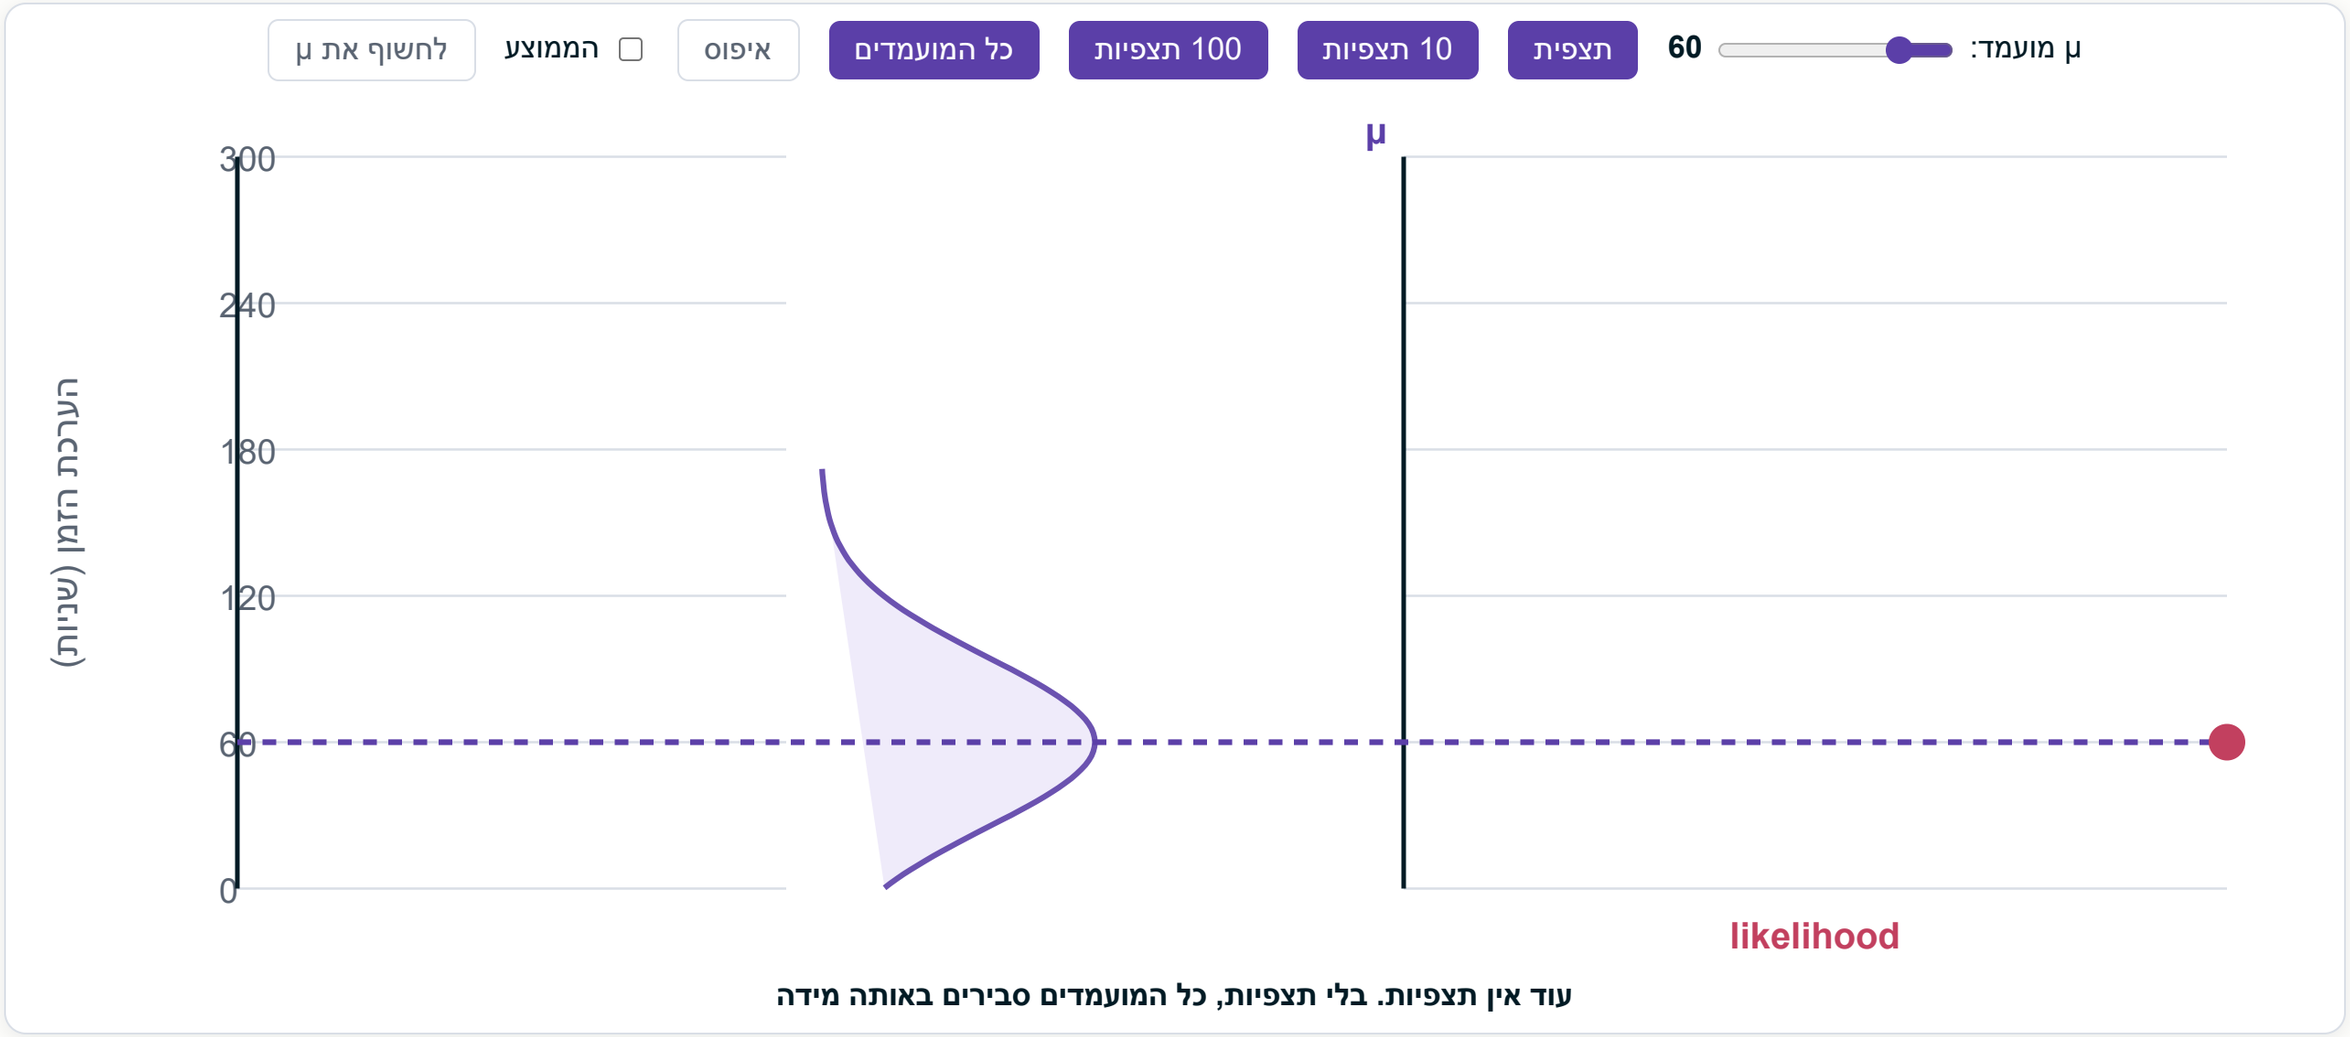
likelihood רציף

- במקום לספור דרכים בלוח, מחשבים לכל תצפית את הצפיפות שלה, $p(y_i \mid \mu, \sigma)$. אותו רעיון, בלי תאים.
- וכמו בלוח, כופלים את כל התצפיות:

$$\mathcal{L}(\mu) = p(y_1 \mid \mu, \sigma) \times p(y_2 \mid \mu, \sigma) \times \cdots \times p(y_n \mid \mu, \sigma)$$

- **הדוגמה:** נבדקים צופים בסרטון מותח באורך 120 שניות, ואחר כך מעריכים כמה זמן הוא נמשך. y היא ההערכה, בשניות.
- בינתיים נניח ש-$\sigma = 35$ ידוע, ונחפש רק את μ.
- **מעכשיו y יופיע על הציר האנכי**, כמו שיהיה ברגרסיה.

likelihood רציף



הזיזו את μ המועמד. הפעמון זז איתו, ותצפיות רחוקות ממנו מחווירות: הצפיפות שלהן קטנה. כל עמדה משאירה נקודה בעקומת ה-**likelihood** שמימין. אחר כך הוסיפו תצפיות, ובדקו שוב.

likelihood רציף

- **בלי תצפיות**, כל המועמדים סבירים באותה מידה: ה-**likelihood** שטוח.
- **כל תצפית** מורידה את הסבירות של מועמדים שרחוקים ממנה, וה-**likelihood** נעשה צר יותר.
- **השיא** נמצא בדיוק בממוצע של התצפיות. זה הממצא של גאוס מ-1809.
- **הרוחב** קטן כשיש יותר תצפיות, וגדל כש-σ גדול.

וגם σ

שני פרמטרים חבויים, ומפה של likelihood

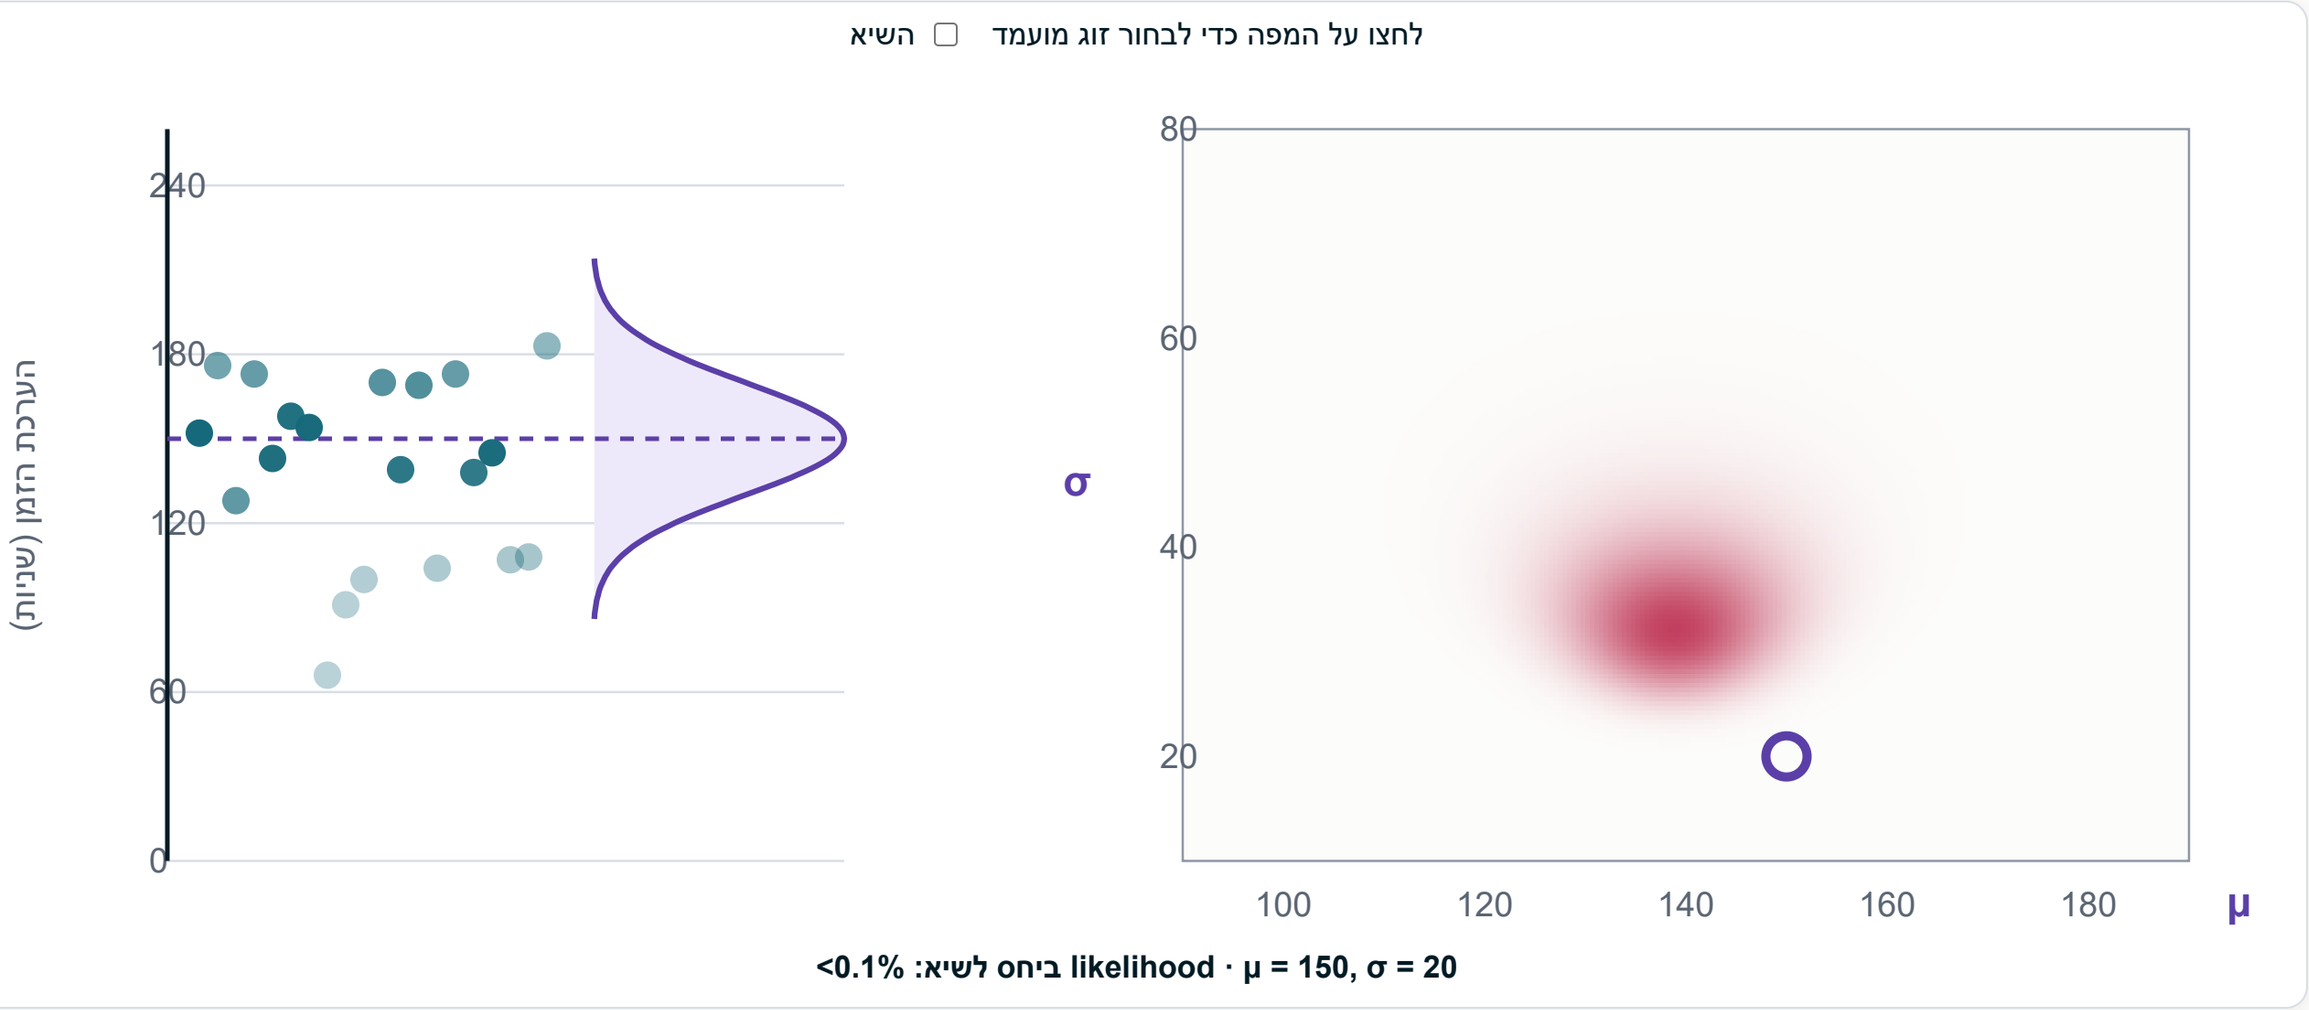
וגם σ

- עד עכשיו הנחנו ש-σ ידוע. במחקר אמיתי גם הוא חבוי: אנחנו לא יודעים מראש כמה הנבדקים שונים זה מזה.
- מועמד הוא עכשיו **זוג**, (μ, σ), ולכל זוג:

$$\mathcal{L}(\mu, \sigma) = \prod_{i=1}^{n} p(y_i \mid \mu, \sigma)$$

- במקום עקומה מקבלים **מפה**: ציר אחד ל-μ, ציר אחד ל-σ, והצבע הוא ה-**likelihood**.
- הנתונים: הערכות הזמן של 20 נבדקים.

וגם σ



כל נקודה במפה היא זוג מועמד: כמה גבוה המרכז, וכמה רחב הפעמון. נסו σ קטן מאוד: התצפיות הרחוקות כמעט בלתי אפשריות. נסו σ גדול מאוד: הפעמון נמוך, וכל תצפית מקבלת צפיפות קטנה. השיא נמצא באמצע.

וגם σ

- **השיא במפה:** μ הוא הממוצע, 138.9 שניות. σ הוא השורש של ממוצע ריבועי הסטיות מהממוצע, 32.2 שניות.
- σ **קטן מדי:** הפעמון צר, והתצפיות הרחוקות כמעט בלתי אפשריות.
- σ **גדול מדי:** הפעמון רחב ונמוך, וכל התצפיות מקבלות צפיפות קטנה.
- **ה-**μ **הטוב ביותר הוא הממוצע, לכל** σ**.** σ קובע רק כמה חד השיא.

שתי שאלות

שאלה ראשונה

האם יש דרך מהירה למצוא את השיא, בלי לחשב את המפה כולה?

שאלה שנייה

קיבלנו את הסיכוי לתצפיות בהינתן כל ערך של הפרמטרים. האם זה באמת מה שאנחנו מחפשים?

שתי התשובות: במצגת הבאה, דרך Bayesian ודרך Frequentist.

סיכום

- **likelihood:** עד כמה התצפיות צפויות, בהינתן ערך מועמד של הפרמטרים.
- **בלוח גלטון:** סופרים בכמה דרכים הלוח, כשהוא מונח על המועמד, מייצר כל תצפית, וכופלים בין התצפיות.
- **ברציף:** במקום דרכים, צפיפות. $\mathcal{L}(\mu, \sigma) = \prod_i p(y_i \mid \mu, \sigma)$.
- **השיא:** μ הוא ממוצע התצפיות, ו-σ הוא שורש הממוצע של ריבועי הסטיות.
- **עוד תצפיות:** ה-likelihood צר יותר.
- **שני פרמטרים:** במקום עקומה, מפה.